

# Effiziente Subgraph-Suche in Datenbanken biologischer Netzwerke: Realisierung und Analyse von Gen-DB

Stephan Epp

23. Januar 2026

## Inhaltsverzeichnis

|          |                                                               |           |
|----------|---------------------------------------------------------------|-----------|
| <b>1</b> | <b>Einführung</b>                                             | <b>4</b>  |
| 1.1      | Beitrag dieser Arbeit . . . . .                               | 4         |
| 1.2      | Aufbau der Arbeit . . . . .                                   | 4         |
| <b>2</b> | <b>Grundlagen</b>                                             | <b>5</b>  |
| 2.1      | Graphen und Adjazenzmatrizen . . . . .                        | 5         |
| 2.2      | Signaturen und Subgraph-Relation . . . . .                    | 5         |
| 2.3      | Der Subgraph Algorithmus . . . . .                            | 6         |
| <b>3</b> | <b>Systemarchitektur von Gen-DB</b>                           | <b>6</b>  |
| 3.1      | Komponentenübersicht . . . . .                                | 6         |
| 3.2      | Datenmodell . . . . .                                         | 7         |
| 3.3      | UML-Architekturmodelle von Gen-DB . . . . .                   | 7         |
| <b>4</b> | <b>Such-Pipeline: Formalisierung und Beweise</b>              | <b>10</b> |
| 4.1      | Problemformulierung . . . . .                                 | 10        |
| 4.2      | SQL-Vorauswahl . . . . .                                      | 10        |
| 4.3      | SQL-Select-Statement . . . . .                                | 11        |
| 4.4      | Gesamtkomplexität der Pipeline . . . . .                      | 11        |
| 4.5      | Korrektheit der Gesamtpipeline . . . . .                      | 12        |
| 4.6      | Effiziente Suche . . . . .                                    | 12        |
| <b>5</b> | <b>Empirische Evaluation</b>                                  | <b>13</b> |
| 5.1      | Versuchsaufbau . . . . .                                      | 13        |
| 5.2      | Generierungsstatistik . . . . .                               | 14        |
| 5.3      | Visualisierung 1: Knoten- und Kantenverteilung . . . . .      | 14        |
| 5.4      | Visualisierung 2: Pre-Filter-Effektivität . . . . .           | 15        |
| 5.5      | Visualisierung 3: Skalierungsverhalten der Suchzeit . . . . . | 15        |
| 5.6      | Visualisierung 4: Trefferverteilung nach Match-Typ . . . . .  | 15        |
| 5.7      | Diskussion . . . . .                                          | 16        |

|          |                                                                       |           |
|----------|-----------------------------------------------------------------------|-----------|
| <b>6</b> | <b>Experimenteller Vergleich</b>                                      | <b>16</b> |
| 6.1      | Versuchsanordnung                                                     | 16        |
| 6.2      | Ergebnis 1: Laufzeitvergleich bei festem $n_A = 5$ , wachsendem $n_B$ | 18        |
| 6.3      | Der Subgraph Algorithmus für $n_B \geq 14$                            | 20        |
| 6.4      | Einordnung in die Literatur effizienter Subgraph-Isomorphie-Verfahren | 22        |
| <b>7</b> | <b>Experimentelle Untersuchung der Parallelisierung</b>               | <b>23</b> |
| 7.1      | Fragestellung und Hypothesen                                          | 25        |
| 7.2      | Implementierung der parallelen Suche                                  | 25        |
| 7.3      | Versuchsaufbau                                                        | 25        |
| 7.4      | Metriken                                                              | 26        |
| 7.5      | Ergebnisse                                                            | 27        |
| 7.5.1    | Die untersuchten Anfragen                                             | 27        |
| 7.5.2    | Gesamtzeit und Speedup                                                | 27        |
| 7.5.3    | Verteilung der Antwortzeiten                                          | 28        |
| 7.5.4    | Skalierung mit der Größe des Suchraums                                | 29        |
| 7.5.5    | Dieselben Anfragen im direkten Vergleich                              | 30        |
| 7.6      | Diskussion                                                            | 31        |
| 7.7      | Grenzen der Untersuchung                                              | 32        |
| 7.8      | Zwischenfazit                                                         | 33        |
| <b>8</b> | <b>Schluss</b>                                                        | <b>33</b> |
| 8.1      | Zusammenfassung                                                       | 33        |
| 8.1.1    | Ausgangspunkt und Zielsetzung                                         | 33        |
| 8.1.2    | Systemarchitektur und Datenmodell                                     | 34        |
| 8.1.3    | Formale Ergebnisse zur Such-Pipeline                                  | 34        |
| 8.1.4    | Empirische Evaluation der Datenbank                                   | 34        |
| 8.1.5    | Experimenteller Vergleich mit VF2                                     | 35        |
| 8.1.6    | Parallelisierung der Kandidatenvergleiche                             | 35        |
| 8.1.7    | Zentrale Erkenntnisse                                                 | 35        |
| 8.1.8    | Abgleich mit den Beiträgen der Arbeit                                 | 36        |
| 8.2      | Kritische Würdigung und Grenzen                                       | 36        |
| 8.3      | Ausblick                                                              | 37        |
| 8.3.1    | Vollständige Suche in beide Richtungen                                | 38        |
| 8.3.2    | Differenzielle Tests der Vorauswahl und Eigenschaftstests             | 38        |
| 8.3.3    | Erweiterung auf gewichtete und beschriftete Subgraph-Isomorphie       | 38        |
| 8.3.4    | Indexierung über Signatur-Hashes                                      | 39        |
| 8.3.5    | Mehrdimensionale Indexstrukturen (R-Baum über $(n_k, m_k)$ )          | 39        |
| 8.3.6    | Zusätzliche notwendige Bedingungen und Label-Indizes                  | 39        |
| 8.3.7    | Weiterführende Parallelisierung                                       | 40        |
| 8.3.8    | Optimierung der Implementierung des Vergleichs                        | 41        |
| 8.3.9    | GPU-Beschleunigung der Signatur- und LCS-Berechnung                   | 41        |
| 8.3.10   | Hybridstrategie: Adaptive Verfahrenswahl nach Kandidatengröße         | 41        |
| 8.3.11   | Asynchrone Suche mit Fortschrittsanzeige und Teilergebnissen          | 42        |
| 8.3.12   | Approximative Suche und geschichtete Stichproben                      | 42        |
| 8.3.13   | Caching häufiger Queries                                              | 43        |
| 8.3.14   | Inkrementelle Aktualisierung der Signatur-Indizes                     | 43        |
| 8.3.15   | Betrieb, Reproduzierbarkeit und Beobachtbarkeit                       | 43        |
| 8.3.16   | Wiederholung und Erweiterung der Parallelisierungsmessung             | 44        |

|        |                                                                    |    |
|--------|--------------------------------------------------------------------|----|
| 8.3.17 | Benchmark-Suite und kontinuierliche Performanzmessung . . . . .    | 44 |
| 8.3.18 | Erweiterung des Vergleichsbenchmarks . . . . .                     | 44 |
| 8.3.19 | Formale Charakterisierung des Übergangsbereichs $\theta$ . . . . . | 45 |
| 8.3.20 | Visuelle Exploration und Graph-Layout . . . . .                    | 46 |
| 8.3.21 | Validierung mit realen Anwendungsfällen . . . . .                  | 46 |
| 8.4    | Priorisierung der nächsten Entwicklungsschritte . . . . .          | 46 |
| 8.5    | Abschließende Bemerkung . . . . .                                  | 47 |

# 1 Einführung

Biologische Datenbanken enthalten heute Millionen von Netzwerken: metabolische Pfade, Protein-Interaktionsnetzwerke und Gen-Regulationsnetzwerke. Eine zentrale Aufgabe bei der Analyse solcher Datenbanken ist die *Subgraph-Suche*: Gegeben sei ein Query-Netzwerk  $G$  (z.B. ein bekanntes Motiv wie ein Teilstück der Glykolyse), gesucht sind alle in der Datenbank gespeicherten Netzwerke  $G'$ , die  $G$  als Subgraphen enthalten.

Diese Arbeit beschreibt die konkrete Realisierung einer solchen Suche im System *Gen-DB*, einer Full-Stack-Anwendung bestehend aus einem PostgreSQL-Backend, einer FastAPI-REST-API und einem Web-Frontend. Das System nutzt den *Subgraph Algorithmus* [1] mit Laufzeit  $O(n^3)$  zur strukturellen Analyse biologischer Netzwerke, dargestellt als Adjazenzmatrizen.

## 1.1 Beitrag dieser Arbeit

- Formale Beschreibung der Systemarchitektur von Gen-DB und Einbettung des Subgraph Algorithmus in eine relationale Datenbank.
- Formaler Nachweis der Korrektheit und Komplexität des Such-Pipeline-Prozesses (Pre-Filtering + Subgraph-Vergleich).
- Empirische Evaluation an einer synthetisch generierten Datenbank mit 1.000.000 biologischen Netzwerken.
- Veranschaulichung der Ergebnisse durch matplotlib-Diagramme: Laufzeitverteilung, Pre-Filter-Effektivität, Skalierungsverhalten und Trefferverteilung.
- Experimenteller Vergleich des Subgraph Algorithmus mit VF2 sowie Analyse der Ursachen der beobachteten Laufzeitunterschiede.
- Experimentelle Untersuchung der parallelen Ausführung der Kandidatenvergleiche mit 1, 2 und 3 Worker-Prozessen (Gesamtzeit, Speedup, Effizienz, Skalierung mit der Kandidatenzahl).
- Zusammenfassung, kritische Würdigung der Grenzen und ausführlicher, nach Themenfeldern geordneter Ausblick auf Erweiterungen (Korrektheit, Indexierung, Beschleunigung der Vergleiche, Systemebene, Evaluation, Anwendung) mit einer Priorisierung der nächsten Schritte.

## 1.2 Aufbau der Arbeit

Die Arbeit gliedert sich in acht Abschnitte, die aufeinander aufbauen: von den theoretischen Grundlagen über das System und seine formale Analyse bis zu den Experimenten und dem Ausblick.

Abschnitt 2 führt in biologische Netzwerke, ihre Adjazenzmatrix-Repräsentation, die Spaltensignaturen und den Subgraph Algorithmus ein, dessen Laufzeit von  $O(n^3)$  die Grundlage aller späteren Betrachtungen ist. Abschnitt 3 beschreibt die Systemarchitektur und das Datenmodell von Gen-DB und erläutert anhand von UML-Paket- und Klassendiagrammen den Aufbau der Anwendung. Abschnitt 4 formalisiert die Such-Pipeline, insbesondere die Vorauswahl anhand von Knoten- und Kantenzahl, und untersucht deren

Korrektheit und Laufzeitkomplexität; ein Serverprotokoll veranschaulicht dort zusätzlich den Ablauf einer konkreten Suche.

Der zweite Teil der Arbeit ist empirisch. Abschnitt 5 stellt den Versuchsaufbau sowie die Ergebnisse zur generierten Datenbank mit einer Million Netzwerken und zum Verhalten der Vorauswahl vor und schließt mit einer Diskussion. Abschnitt 6 widmet sich dem experimentellen Vergleich mit etablierten Verfahren, analysiert die beobachteten Laufzeitunterschiede und ordnet die Verfahren in die Fachliteratur ein. Abschnitt 7 untersucht anschließend, wie sich die gesamte Suche verhält, wenn die Kandidatenvergleiche auf mehrere Prozesse verteilt werden. Er beschreibt die Implementierung der parallelen Ausführung, ein reproduzierbares Experiment mit einem, zwei und drei Worker-Prozessen und die Auswertung nach Gesamtzeit, Speedup, Effizienz und Skalierung mit der Kandidatenzahl.

Das abschließende Kapitel „Schluss“ (Abschnitt 8) besteht aus fünf Teilen. Es fasst die Ergebnisse aller Abschnitte zusammen (Abschnitt 8.1), benennt die Grenzen der Arbeit (Abschnitt 8.2), entwickelt einen ausführlichen, nach Themenfeldern geordneten Ausblick mit möglichen Erweiterungen und offenen Forschungsfragen (Abschnitt 8.3), schlägt eine Reihenfolge für die nächsten Entwicklungsschritte vor (Abschnitt 8.4) und schließt mit einer Gesamteinschätzung (Abschnitt 8.5).

## 2 Grundlagen

### 2.1 Graphen und Adjazenzmatrizen

**Definition 1** (Biologisches Netzwerk). Ein biologisches Netzwerk ist ein gerichteter Graph  $G = (V, E)$  mit Knotenmenge  $V = \{v_1, \dots, v_n\}$  (Metabolite, Proteine oder Gene) und Kantenmenge  $E \subseteq V \times V$  (Reaktionen, Interaktionen oder Regulationsbeziehungen). Jedem Knoten  $v_i$  ist ein Label  $\ell(v_i) \in \Sigma_{\text{Bio}}$  aus einem biologischen Vokabular zugeordnet.

**Definition 2** (Adjazenzmatrix-Repräsentation). Ein Netzwerk  $G$  mit  $n$  Knoten wird in Gen-DB als Tupel

$$G = (L, A) \quad \text{mit } L \in \Sigma_{\text{Bio}}^n, A \in \{0, 1\}^{n \times n}$$

gespeichert, wobei  $L$  der Vektor der Knotenlabels und  $A$  die Adjazenzmatrix mit  $A_{ij} = 1 \Leftrightarrow (v_i, v_j) \in E$  ist.

### 2.2 Signaturen und Subgraph-Relation

**Definition 3** (Spaltensignatur). Für eine Adjazenzmatrix  $A \in \{0, 1\}^{n \times n}$  ist die Signatur der Spalte  $j$  definiert als

$$\sigma_j(A) = \sum_{i=0}^{n-1} A_{ij} \cdot 2^i + j \cdot 2^n.$$

**Definition 4** (Signatur-Array und Hash). Das Signatur-Array von  $A$  ist  $\Sigma(A) = (\sigma_0(A), \dots, \sigma_{n-1}(A))$ . Der Signatur-Hash ist

$$h(A) = \text{SHA256}(\text{str}(\Sigma(A))).$$

**Lemma 1** (Injektivität der Signaturfunktion). Die Abbildung  $\sigma : \{0, 1\}^n \times \{0, \dots, n-1\} \rightarrow \mathbb{N}$ ,  $(c, j) \mapsto \sum_{i=0}^{n-1} c_i 2^i + j 2^n$  ist injektiv.

*Beweis.* Sei  $\sigma(c, j) = \sigma(c', j')$ . Da  $\sum_{i=0}^{n-1} c_i 2^i \in [0, 2^n - 1]$  und  $j2^n, j'2^n$  Vielfache von  $2^n$  sind, folgt aus der Eindeutigkeit der Division mit Rest (Divisionsalgorithmus für  $2^n$ ), dass  $j = j'$  und somit  $\sum c_i 2^i = \sum c'_i 2^i$ . Da die Binärdarstellung eindeutig ist, folgt  $c = c'$ .  $\square$

**Definition 5** (Subgraph-Relation, zyklisch). Für Adjazenzmatrizen  $A \in \{0, 1\}^{n_A \times n_A}$  und  $B \in \{0, 1\}^{n_B \times n_B}$  mit  $n_A \leq n_B$  schreiben wir  $A \preceq B$  (“ $A$  ist zyklischer Subgraph von  $B$ ”), wenn es eine zyklische Rotation  $r \in \{0, \dots, n_B - 1\}$  und eine Startposition  $s$  gibt, sodass die Zeilenkomponenten der Signaturen von  $A$  als längste gemeinsame Teilsequenz (LCS) der Länge  $\geq 2$  in der rotierten Zeilenkomponentensequenz von  $B$  ab Position  $s$  auftreten.

## 2.3 Der Subgraph Algorithmus

Der Subgraph Algorithmus [1] berechnet für zwei Matrizen  $A, B$  in drei Schritten, ob  $A \preceq B$ ,  $B \preceq A$ , beide äquivalent oder unvergleichbar sind:

1. Berechne  $\Sigma(A)$  und  $\Sigma(B)$  — Aufwand  $O(n_A^2 + n_B^2)$ .
2. Extrahiere Zeilenkomponenten  $\rho(A) = (\sigma_j(A) \bmod 2^{n_A})_j$ , analog für  $B$ .
3. Für jede der  $n_B$  zyklischen Rotationen von  $\rho(B)$ : Vergleiche mit  $\rho(A)$  via LCS in  $O(n_A \cdot n_B)$ .

**Satz 1** (Laufzeit des Subgraph Algorithmus). Für  $n = \max(n_A, n_B)$  benötigt der Subgraph Algorithmus  $O(n^3)$  Zeit.

*Beweis.* Schritt 1 ist  $O(n^2)$ . Schritt 3 besteht aus  $n_B \leq n$  Rotationen, jede mit LCS-Vergleich in  $O(n_A n_B) \subseteq O(n^2)$ , insgesamt  $O(n^3)$ . Schritt 2 ist  $O(n)$ . Die Summe ist  $O(n^2) + O(n) + O(n^3) = O(n^3)$ .  $\square$

Eine vollständige Optimalitätsanalyse  $\Omega(n^{3-\epsilon})$  unter SETH findet sich in [1]; sie wird hier als gegeben vorausgesetzt und in Abschnitt 4 auf den Datenbankkontext übertragen.

## 3 Systemarchitektur von Gen-DB

### 3.1 Komponentenübersicht

Gen-DB besteht aus drei Schichten:

- **Frontend** (HTML/CSS/JavaScript): Erstellung, Anzeige und Suche von Netzwerken über REST-Aufrufe.
- **Backend** (FastAPI, Python): REST-Endpunkte `/api/networks`, `/api/networks/{id}`, `/api/networks/search`; Modul `crud.py` implementiert Signaturberechnung und ruft den Subgraph Algorithmus auf.
- **Datenbank** (PostgreSQL): Tabellen `biological_networks` (Metadaten: Name, Typ, Organismus, Knoten-/Kantenzahl) und `network_matrices` (Knotenlabels, Adjazenzmatrix, Signatur-Array, Signatur-Hash).

**Definition 6** (Datenbankzustand). Der Datenbankzustand zum Zeitpunkt  $t$  ist eine endliche Menge

$$\mathcal{D}_t = \{(id_k, L_k, A_k, \Sigma_k, h_k) : k = 1, \dots, N_t\},$$

wobei  $N_t = |\mathcal{D}_t|$  die Anzahl gespeicherter Netzwerke ist. In der vorliegenden Evaluation gilt  $N_t \approx 1.000.002$ .

## 3.2 Datenmodell

Die Speicherung erfolgt normalisiert über zwei 1:1-verknüpfte Relationen:

`biological_networks(network_id, name, type, organism, node_count, edge_count)`

`network_matrices(network_id, L, A,  $\Sigma$ , h)`

Die Spalten `node_count` und `edge_count` entsprechen  $n_k = |V_k|$  bzw.  $m_k = |E_k| = \sum_{i,j} (A_k)_{ij}$  und werden für das Pre-Filtering (Abschnitt 4.2) materialisiert, um eine vollständige Tabellenabtastung zu vermeiden.

## 3.3 UML-Architekturmodelle von Gen-DB

Die beiden UML-Diagramme in den Abbildungen 1 und 2 dokumentieren die Struktur von Gen-DB auf Paket- und Klassenebene und bilden damit die konzeptionelle Grundlage für die in den folgenden Abschnitten formalisierten Such- und Datenbankprozesse.

Das Paketdiagramm zeigt die fachliche und technische Zerlegung der Anwendung in drei logisch getrennte Bausteine: das Web-Frontend, das Backend mit den API- und Suchkomponenten und die persistente Datenspeicherung in PostgreSQL. Dieser Aufbau ist keine rein dokumentarische Anordnung, sondern entspricht einem klaren Entwurfsmuster für skalierbare Datenbankanwendungen: Die Präsentationsschicht übernimmt keine Datenlogik, sondern stellt lediglich die Interaktion mit dem Benutzer bereit; die Logikschicht kapselt die Kernfunktionalität der Signaturberechnung, des Pre-Filters und des Subgraph-Checks; die Datenbankschicht speichert neben den Netzwerkinhalten auch die maschinenlesbaren Repräsentationen, die für die Suche benötigt werden. Aus Sicht der Systemarchitektur ist deshalb besonders wichtig, dass die Datenflussrichtung zwischen den Schichten eindeutig ist: Ein Nutzer erzeugt oder lädt ein biologisches Netzwerk über das Frontend; die Anfrage wird als API-Request an das Backend weitergeleitet; dort werden Netzwerkdaten interpretiert, normalisiert und in Form von Knotenlabels und Adjazenzmatrizen für den Subgraph-Algorithmus aufbereitet; danach werden die passenden Kandidaten mit SQL-Filterkriterien aus der Datenbank abgerufen und im Ergebnis an die Präsentationsschicht zurückgegeben. Das Paketdiagramm macht damit sichtbar, dass Gen-DB als System nicht nur aus einer einzelnen Anwendung besteht, sondern aus einer zusammengesetzten, modularen Architektur, in der fachliche Trennung und technische Verantwortlichkeit klar voneinander abgegrenzt sind.

Die in der übrigen Arbeit beschriebene Such-Pipeline baut genau auf dieser Struktur auf. Die Datenbank hält nicht nur die Netzwerkmetadaten wie Name, Organismus und Typ, sondern auch die strukturellen Repräsentationen in einer für schnelle Filterung geeigneten Form. Die Backend-Komponenten sind dafür zuständig, die Suchanfrage in eine Folge von Vorfilter-, Vergleichs- und Ergebnisphasen zu übersetzen. Das Paketdiagramm zeigt somit die organisatorische Ebene des Systems: welche Komponenten miteinander interagieren, welche Verantwortlichkeiten sie übernehmen und wo die fachlichen Grenzen verlaufen. Diese Abgrenzung ist für das Verständnis der späteren Komplexitäts- und Korrektheitsbeweise entscheidend, weil sie präzise zeigt, wo der algorithmische Kern liegt und wo rein relationale oder benutzerorientierte Aufgaben ausgelagert werden.

Das Klassendiagramm ergänzt diese Sicht um den objektorientierten bzw. modellorientierten Entwurf der einzelnen Daten- und Dienstekomponenten. Es macht deutlich, dass die Systemlogik nicht auf lose, unstrukturierte Listen von Werten beruht, sondern auf

semantisch geordneten Entitäten: Netzwerkobjekte, Knoten- und Kanteninformationen, Matrixrepräsentationen, Signaturdaten und Suchresultate sind als getrennte Strukturen modelliert. Ein wesentlicher Entwurfspunkt ist die Trennung zwischen der biologischen Netzwerkanalyse und der relationalen Persistenz. Während die Datenbankrelationen die langfristige Speicherung, Indizierung und Abfrage von Netzwerken garantieren, repräsentiert das Klassendiagramm die fachlichen Informationen im Laufzeitkontext der Anwendung. So sind etwa Metadaten wie Typ, Organismus und Knotenzahl in der Klasse bzw. im Datensatz des Netzwerks als formale Eigenschaften modelliert, während die Adjazenzmatrix und die Signatur-Arrays als strukturgebende Merkmale dienen, die für die Subgraph-Relation maßgeblich sind. Dadurch wird die Verbindung zwischen biologischer Semantik und algorithmisch nutzbarer Repräsentation explizit sichtbar.

Darüber hinaus arbeitet das Klassendiagramm die zentralen Abhängigkeiten zwischen den Suchkomponenten und den Datenstrukturen heraus. Die Signaturberechnung ist nicht isoliert, sondern Teil einer größeren Verarbeitungskette, in der ein Query-Netzwerk mit den gespeicherten Netzwerken verglichen wird, Kandidaten über notwendige Bedingungen vorgefiltert werden und anschließend der Subgraph-Algorithmus entscheidet, ob ein Treffer tatsächlich vorliegt. Diese Abhängigkeiten sind im UML-Modell als Assoziationen und Verantwortlichkeiten nachvollziehbar: Jede Klasse trägt eine bestimmte Rolle in der Suche, aber die fachliche Koordination geschieht über das Zusammenspiel der Komponenten, nicht über eine monolithische Implementierung. Genau dieser modularisierte Aufbau ist es, der die Skalierbarkeit und Analysefähigkeit von Gen-DB erklärt: Die Datenmodellierung unterstützt die Suche, die Suchlogik verwendet die Repräsentation, und die Systemarchitektur koordiniert die Kommunikationspfade zwischen Nutzer, API und Datenbank.

Die beiden Diagramme zusammen leisten also mehr als nur eine Visualisierung des Quellcodes: Sie dokumentieren die Entwurfslogik des Systems als Ganzes. Sie zeigen, dass Gen-DB ein typisches Full-Stack-System ist, dessen Stärke nicht in einer einzelnen technischen Komponente, sondern in der engen Verknüpfung von semantischer Modellierung, datenbankseitiger Indexierung und algorithmischer Subgraph-Erkennung liegt. Gerade diese Architektur ist der Grund, warum die folgenden Abschnitte die Laufzeit, die Korrektheit und die Kandidatenreduktion formal analysieren können: Die Struktur des Systems ist so klar und modular, dass die mathematische Modellierung der Pipeline direkt auf die reale Implementierung zurückgeführt werden kann.




Abbildung 1: UML-Paketdiagramm der Gen-DB-Architektur.




Abbildung 2: UML-Klassendiagramm der Gen-DB-Datenmodellierung und Suche.

## 4 Such-Pipeline: Formalisierung und Beweise

### 4.1 Problemformulierung

**Definition 7** (Datenbank-Subgraph-Suche). Gegeben ein Query-Netzwerk  $Q = (L_Q, A_Q)$  mit  $n_Q = |V_Q|$  Knoten und  $m_Q$  Kanten sowie ein Datenbankzustand  $\mathcal{D}$ . Die Such-Pipeline berechnet die Treffermenge

$$\text{Match}(Q, \mathcal{D}) = \{(id_k, L_k, A_k) \in \mathcal{D} : A_Q \preceq A_k \text{ oder } A_k \preceq A_Q\},$$

annotiert mit dem jeweiligen Treffertyp (**exact** oder **subgraph**).

### 4.2 SQL-Vorauswahl

Die zentrale Idee der Gen-DB-Suche besteht darin, den teuren strukturellen Vergleich nicht mit sämtlichen gespeicherten Netzwerken durchzuführen. Stattdessen wird der Suchraum zunächst direkt in der Datenbank durch eine kostengünstige Vorauswahl verkleinert. Dazu werden zwei leicht verfügbare Kennzahlen des Query-Netzwerks mit den entsprechenden Kennzahlen der gespeicherten Netzwerke verglichen: die Knotenzahl und die Kantenanzahl. Für die hier betrachtete Richtung, in der das Query-Netzwerk in einem gespeicherten Netzwerk enthalten sein soll, kann ein gespeichertes Netzwerk mit weniger Knoten oder weniger Kanten kein Treffer sein. Solche Einträge werden daher bereits bei der Selektion ausgeschlossen, bevor ihre Adjazenzmatrix geladen und mit dem Subgraph-Algorithmus untersucht wird.

Die Vorauswahl vergleicht dabei zunächst die Anzahlen, nicht die konkreten Knotenlabels oder die Position jeder einzelnen Kante. Sind beide Schranken erfüllt, bleibt ein Netzwerk ein möglicher Kandidat; ob seine konkrete Struktur tatsächlich zum Query passt, entscheidet erst der anschließende Subgraph-Vergleich. Beispielsweise kann ein Query mit acht Knoten und fünfzehn Kanten nur gespeicherte Netzwerke mit mindestens acht Knoten und mindestens fünfzehn Kanten als Kandidaten zulassen. Ein Eintrag mit sieben Knoten oder vierzehn Kanten lässt sich sicher ausschließen, während ein Eintrag mit acht Knoten und fünfzehn Kanten noch kein Treffer garantiert. Diese Trennung zwischen billiger, datenbankseitiger Kandidatenreduktion und genauer, algorithmischer Prüfung spart insbesondere bei großen Datenbanken unnötige Matrixübertragungen und Subgraph-Vergleiche, ohne für die Richtung  $A_Q \preceq A_k$  bei vollständiger Kandidatenbetrachtung echte Treffer zu verlieren. Die folgenden Bedingungen formalisieren diese Vorauswahl.

**Lemma 2** (Notwendige Bedingung für  $\preceq$ ). Wenn  $A_Q \preceq A_k$ , so gilt  $n_Q \leq n_k$  und  $m_Q \leq m_k$ .

*Beweis.* Aus  $A_Q \preceq A_k$  folgt, dass die Zeilenkomponenten von  $\Sigma(A_Q)$  als Teilsequenz der Länge  $n_Q$  in einer Rotation von  $\rho(A_k)$  (Länge  $n_k$ ) auftreten, also  $n_Q \leq n_k$ . Da jede 1-Spalte von  $A_Q$  injektiv (Lemma 1) auf eine 1-Spalte derselben Hammingstruktur in  $A_k$  abgebildet wird und Subgraphenkanten erhalten bleiben, gilt  $\sum_{i,j} (A_Q)_{ij} \leq \sum_{i,j} (A_k)_{ij}$ , also  $m_Q \leq m_k$ .  $\square$

**Korollar 1** (Korrektheit des Pre-Filters). Sei

$$\mathcal{C}(Q, \mathcal{D}) = \{(id_k, L_k, A_k) \in \mathcal{D} : n_k \geq n_Q \wedge m_k \geq m_Q\}.$$

Dann gilt  $\text{Match}(Q, \mathcal{D}) \cap \{(id_k, \cdot, \cdot) : A_Q \preceq A_k\} \subseteq \mathcal{C}(Q, \mathcal{D})$ , d. h. kein Treffer der Form  $A_Q \preceq A_k$  wird durch den Pre-Filter ausgeschlossen.

*Beweis.* Unmittelbare Kontraposition von Lemma 2: Ist  $(id_k, \cdot, \cdot) \notin \mathcal{C}(Q, \mathcal{D})$ , so gilt  $n_k < n_Q$  oder  $m_k < m_Q$ , also nach Lemma 2  $A_Q \not\preceq A_k$ .  $\square$

**Bemerkung 1.** Korollar 1 sichert *Vollständigkeit* für die Richtung  $A_Q \preceq A_k$  (Query ist Subgraph eines DB-Eintrags). Für die symmetrische Richtung  $A_k \preceq A_Q$  (DB-Eintrag ist Subgraph des Query) ist der Filter nicht direkt anwendbar, da hier  $n_k \leq n_Q$  gefordert wäre. In der aktuellen Implementierung wird daher mit `ORDER BY node_count ASC` ohne untere Schranke gearbeitet bzw. die Filterbedingung situativ umgekehrt, vgl. Abschnitt 8.

### 4.3 SQL-Select-Statement

Listing 1: Pre-Filter-Query

```

1 SELECT bn.network_id, bn.name, bn.network_type, bn.organism,
2       bn.node_count, bn.edge_count,
3       nm.node_labels, nm.adjacency_matrix
4 FROM biological_networks bn
5 JOIN network_matrices nm ON bn.network_id = nm.network_id
6 WHERE bn.node_count >= %s AND bn.edge_count >= %s
7 ORDER BY bn.node_count ASC
8 LIMIT %s;
```

Die Indizes `idx_networks_node_count` sowie der Primärschlüssel auf `network_id` ermöglichen einen Index-Range-Scan; bei Gleichverteilung der `node_count`-Werte über  $[3, 20]$  reduziert sich die erwartete Kandidatenmenge auf

$$\mathbb{E}[|\mathcal{C}(Q, \mathcal{D})|] \approx N \cdot \Pr[n_k \geq n_Q] \cdot \Pr[m_k \geq m_Q].$$

### 4.4 Gesamtkomplexität der Pipeline

**Satz 2** (Komplexität der Datenbanksuche). Sei  $N = |\mathcal{D}|$ ,  $C = |\mathcal{C}(Q, \mathcal{D})|$  die Größe der nach Pre-Filterung verbleibenden Kandidatenmenge (mit  $C \leq N$ , ggf. begrenzt durch `max_candidates`),  $n = \max(n_Q, n_{\max})$  mit  $n_{\max} = \max_{k \in \mathcal{C}} n_k$ . Dann beträgt die Gesamtlauzeit der Suche

$$T_{\text{Suche}}(N, C, n) = O\left(\underbrace{\log N + C}_{\text{Pre-Filter (Index-Scan)}}\right) + O\left(\underbrace{C \cdot n^3}_{\text{Subgraph-Vergleiche}}\right).$$

*Beweis.* Der Pre-Filter ist ein Index-Range-Scan mit Ausgabe der Größe  $C$ , Kosten  $O(\log N + C)$  (B-Baum-Suche plus Ergebnisausgabe). Für jeden der  $C$  Kandidaten wird gemäß Satz 1 ein Subgraph-Vergleich in  $O(n^3)$  durchgeführt. Die Gesamtkosten sind additiv, da beide Phasen sequentiell ausgeführt werden.  $\square$

**Korollar 2** (Asymptotisches Verhalten bei konstanter Knotenzahl). Ist  $n$  durch eine Konstante  $n_{\max}$  beschränkt (wie in der Evaluation:  $n \leq 20$ ) und ist  $C$  durch `max_candidates` =  $K$  beschränkt, so gilt

$$T_{\text{Suche}}(N) = O(\log N) + O(1),$$

d. h. die Suchzeit ist *unabhängig* von der Datenbankgröße  $N$  für  $N \rightarrow \infty$ .

Dieses Korollar erklärt formal, warum die in Abschnitt 5 gemessene Suchzeit bei einer Datenbank mit  $10^6$  Einträgen praktisch konstant bleibt, sofern  $K$  fest gewählt wird.

## 4.5 Korrektheit der Gesamtpipeline

**Satz 3** (Korrektheit). Sei  $K = \infty$  (kein Kandidatenlimit). Dann gilt

$$\{(id_k, L_k, A_k) \in \mathcal{D} : A_Q \preceq A_k\} \subseteq \text{Output}(Q, \mathcal{D}),$$

d. h. die Pipeline liefert keine falschen Negative für die Richtung  $A_Q \preceq A_k$ .

*Beweis.* Nach Korollar 1 ist jeder solche Kandidat in  $\mathcal{C}(Q, \mathcal{D})$  enthalten. Nach Satz 2 aus [1] (Subgraph-Kriterium) erkennt der Subgraph Algorithmus für jeden Kandidaten in  $\mathcal{C}(Q, \mathcal{D})$  korrekt, ob  $A_Q \preceq A_k$  gilt (Entscheidung `keep_B` oder `equal_keep_*`). Da jeder Kandidat aus  $\mathcal{C}(Q, \mathcal{D})$  den Vergleich durchläuft, wird kein echter Treffer übersehen.  $\square$

**Bemerkung 2.** Mit  $K < \infty$  (praktisch:  $K = 10.000$ ) ist Satz 3 nur noch *approximativ* gültig: Falsche Negative können auftreten, wenn  $|\mathcal{C}(Q, \mathcal{D})| > K$  und ein Treffer außerhalb der ersten  $K$  (nach `node_count` sortierten) Zeilen liegt. Abschnitt 8 diskutiert hierfür ein geschichtetes Stichprobenverfahren.

## 4.6 Effiziente Suche

Das folgende Serverprotokoll aus der README dokumentiert den Betrieb der FastAPI-Anwendung und eine konkrete Suche über den Endpunkt `/api/networks/search`. Vor der Suche werden beispielhaft die Listen- und Detailendpunkte aufgerufen. Die Ausgabe ist hier unverändert wiedergegeben:

Listing 2: Serverprotokoll zur Suche in Gen-DB

```
1 (venv) PS C:\Users\sepp5\Git\gen-db> uvicorn backend.app:app --app-dir src --  
   ↪ reload --port 8000  
2 INFO: Will watch for changes in these directories: ['C:\\Users\\sepp5\\Git\\gen-  
   ↪ db']  
3 INFO: Uvicorn running on http://127.0.0.1:8000 (Press CTRL+C to quit)  
4 INFO: Started reloader process [11520] using WatchFiles  
5 INFO: Started server process [20388]  
6 INFO: Waiting for application startup.  
7 INFO: Application startup complete.  
8 2026-06-24 07:40:50 [INFO] GET /api/networks limit=33 random=True  
9 2026-06-24 07:40:50 [INFO] get_all_networks: limit=33 random_sample=True  
10 2026-06-24 07:40:51 [INFO] get_all_networks: Fetched 33 records  
11 2026-06-24 07:40:51 [INFO] GET /api/networks - Returned 33 networks  
12 INFO: 127.0.0.1:64651 - "GET /api/networks?limit=33&random=true HTTP/1.1" 200 OK  
13 2026-06-24 07:40:59 [INFO] GET /api/networks limit=33 random=True  
14 2026-06-24 07:40:59 [INFO] get_all_networks: limit=33 random_sample=True  
15 2026-06-24 07:41:01 [INFO] get_all_networks: Fetched 33 records  
16 2026-06-24 07:41:01 [INFO] GET /api/networks - Returned 33 networks  
17 INFO: 127.0.0.1:49775 - "GET /api/networks?limit=33&random=true HTTP/1.1" 200 OK  
18 2026-06-24 07:42:46 [INFO] GET /api/networks/820154  
19 2026-06-24 07:42:46 [INFO] get_network_by_id: network_id=820154  
20 2026-06-24 07:42:47 [INFO] get_network_by_id: Found network 'metabolic_C.  
   ↪ _elegans_820154'  
21 2026-06-24 07:42:47 [INFO] GET /api/networks/820154 - Found: metabolic_C.  
   ↪ _elegans_820154  
22 INFO: 127.0.0.1:51144 - "GET /api/networks/820154 HTTP/1.1" 200 OK
```

|    |                                                                                                            |
|----|------------------------------------------------------------------------------------------------------------|
| 23 | 2026-06-24 07:43:04 [INFO] POST /api/networks/search - nodes=15                                            |
| 24 | 2026-06-24 07:43:27 [INFO] search_subgraph: 306261 candidates for query (n=15, e<br>$\hookrightarrow$ =62) |
| 25 | 2026-06-24 07:47:31 [INFO] search_subgraph: Found 306260 matches                                           |
| 26 | 2026-06-24 07:47:31 [INFO] POST /api/networks/search - Found 306260 matches                                |
| 27 | INFO: 127.0.0.1:52597 - "POST /api/networks/search HTTP/1.1" 200 OK                                        |

Das Protokoll zeigt zunächst, dass der Entwicklungsserver mit Uvicorn startet und seine Anwendung erfolgreich initialisiert. Zwei Anfragen an `GET /api/networks?limit=33&random=true` liefern jeweils 33 zufällig ausgewählte Datensätze; beide enden mit dem HTTP-Status 200 OK. Der spätere Aufruf von `GET /api/networks/820154` löst den Eintrag `metabolic_C._elegans_820154` auf und wird ebenfalls erfolgreich beantwortet. Diese Aufrufe belegen die Erreichbarkeit der Leseendpunkte, sind aber selbst kein Leistungstest der Subgraph-Suche.

Der Suchaufruf wird um 07:43:04 protokolliert. Die Anfrage enthält ein Query-Netzwerk mit 15 Knoten; bei der Kandidatenmeldung um 07:43:27 werden zusätzlich 62 Kanten ausgewiesen. Zwischen dem Eingang der Anfrage und dieser Meldung liegen rund 23 Sekunden. Anschließend meldet der Suchdienst um 07:47:31 insgesamt 306.261 untersuchte Kandidaten und 306.260 Treffer. Vom Kandidatenprotokoll bis zur Ergebnismeldung vergehen damit rund 4 Minuten und 4 Sekunden; vom Eingang der Anfrage bis zur abschließenden Erfolgsmeldung sind es rund 4 Minuten und 27 Sekunden. Die Zeitwerte sind aus den Zeitstempeln auf Sekundengenauigkeit abgeleitet und umfassen die protokollierten Phasen, nicht notwendigerweise ausschließlich die reine Rechenzeit des Vergleichsalgorithmus.

In diesem Lauf wurde somit genau ein Kandidat nicht als Treffer gezählt; der Anteil der gemeldeten Treffer an den Kandidaten beträgt rund 99,9997%. Die hohe Quote ist eine Eigenschaft dieses konkreten Querys und der verwendeten Datenbank, keine allgemeine Aussage über die Trefferwahrscheinlichkeit. Ebenso lässt sich aus dem Protokoll allein keine Selektivität des Pre-Filters berechnen: Dafür müsste zusätzlich die Gesamtzahl der Datenbankinträge vor der Vorauswahl bekannt sein. Es ist daher nicht belegt, welcher Anteil aller gespeicherten Netzwerke durch den Filter ausgeschlossen wurde.

Für die Laufzeitinterpretation ist vor allem die große Kandidatenmenge relevant. Der protokollierte Aufruf liefert am Ende den Status 200 OK, benötigt aber über vier Minuten bis zur Suchergebnismeldung. Dies veranschaulicht den in Satz 2 beschriebenen Einfluss der Kandidatenzahl  $C$ : Selbst wenn die Vorauswahl teure Vergleiche vermeidet, muss die verbleibende Menge strukturell geprüft werden. Das Beispiel belegt den erfolgreichen Ende-zu-Ende-Ablauf und die Verarbeitung einer umfangreichen Kandidatenmenge, nicht jedoch für sich allein eine allgemein kurze Antwortzeit oder eine Skalierung unabhängig von der Datenbankgröße. Für solche Aussagen sind kontrollierte Messreihen mit dokumentierter Datenbankgröße, Query-Struktur, Kandidatenzahl und Laufzeit erforderlich; diese werden in Abschnitt 5 separat betrachtet.

## 5 Empirische Evaluation

### 5.1 Versuchsaufbau

Die Datenbank wurde mit einem Generierungsskript befüllt, das  $N = 1.000.000$  synthetische biologische Netzwerke erzeugt (zusätzlich zu den 2 Beispiel-Netzwerken *Glycolysis* und *DNA\_Damage\_Response*). Für jedes Netzwerk wurde:

- die Knotenzahl  $n_k \sim \mathcal{U}\{3, \dots, 20\}$  gleichverteilt gewählt,
- jede Kante unabhängig mit Wahrscheinlichkeit  $p = 0,3$  gesetzt (Erdős–Rényi-Modell  $G(n_k, p)$ , ohne Selbstkanten),
- der Netzwerktyp aus `{metabolic, protein, gene_regulation}` gleichverteilt gewählt,
- der Organismus aus 7 Spezies gleichverteilt gewählt.

**Lemma 3** (Erwartete Kantenzahl). Für  $A \sim G(n, p)$  mit verbotenen Selbstkanten gilt

$$\mathbb{E}[m] = p \cdot n(n - 1).$$

*Beweis.* Es gibt  $n(n - 1)$  geordnete Paare  $(i, j)$ ,  $i \neq j$ . Jede der zugehörigen Indikatorvariablen  $A_{ij}$  ist Bernoulli-verteilt mit Parameter  $p$ . Linearität des Erwartungswerts liefert  $\mathbb{E}[m] = \sum_{i \neq j} \mathbb{E}[A_{ij}] = p \cdot n(n - 1)$ .  $\square$

Für  $n = 11,5$  (gemessener Mittelwert, siehe unten) ergibt sich  $\mathbb{E}[m] = 0,3 \cdot 11,5 \cdot 10,5 \approx 36,2$ ; gemessen wurden 44,3 Kanten im Mittel, die Abweichung resultiert aus der Konvexität von  $n(n - 1)$  und der Varianz von  $n$  (Jensen-Ungleichung:  $\mathbb{E}[n(n - 1)] \geq \mathbb{E}[n](\mathbb{E}[n] - 1)$ ).

## 5.2 Generierungsstatistik

Tabelle 1: Statistik der generierten Datenbank ( $N = 1.000.000$ )

| Netzwerktyp     | Anzahl    | Anteil |
|-----------------|-----------|--------|
| protein         | 333.670   | 33,37% |
| gene_regulation | 333.485   | 33,35% |
| metabolic       | 332.845   | 33,28% |
| <b>Gesamt</b>   | 1.000.000 | 100%   |

Mittlere Knotenzahl:  $\bar{n} = 11,5$ ; mittlere Kantenzahl:  $\bar{m} = 44,3$ . Die Generierung mit Batch-Größe 5000 erreichte einen Durchsatz von  $\approx 1800$  Netzwerken/Sekunde, Gesamtzeit 9,27 Minuten.

## 5.3 Visualisierung 1: Knoten- und Kantenverteilung

Abbildung 3 zeigt die (in der Generierung) gleichverteilte Knotenzahl sowie die approximativ binomialverteilte Kantenzahl pro Netzwerk.

**Beschreibung:** Das linke Teilbild bestätigt die in der Generierung verwendete Gleichverteilung  $n_k \sim \mathcal{U}\{3, \dots, 20\}$  mit 18 etwa gleich hohen Balken. Das rechte Teilbild zeigt die Kantenzahlverteilung als Überlagerung von 18 Binomialverteilungen  $\text{Bin}(n_k(n_k - 1), 0,3)$ , gewichtet mit der jeweiligen Häufigkeit von  $n_k$ . Die resultierende Verteilung ist rechtsschief mit Modus um 30–40 Kanten und einem langen Ausläufer bis  $\approx 342$  (für  $n = 19$ :  $n(n - 1) = 342$ ).




Abbildung 3: Histogramm der Knotenzahl  $n_k$  (links, diskret-gleichverteilt auf  $\{3, \dots, 20\}$ ) und der Kantenanzahl  $m_k$  (rechts, approximativ binomialverteilt mit  $\mathbb{E}[m] \approx p \cdot n(n-1)$ ) über alle  $N = 1.000.000$  generierten Netzwerke.

## 5.4 Visualisierung 2: Pre-Filter-Effektivität

**Beschreibung:** Für ein Query-Netzwerk mit  $n_Q$  Knoten und der erwarteten Kantenanzahl  $\mathbb{E}[m_Q] = 0,3 n_Q(n_Q - 1)$  wird

$$|\mathcal{C}(Q, \mathcal{D})| \approx N \cdot \Pr[n_k \geq n_Q]$$

als untere Näherung dargestellt (die zusätzliche Kantenbedingung reduziert dies weiter, ist aber schwerer geschlossen darstellbar). Die Kurve fällt von  $|\mathcal{C}| \approx N$  für  $n_Q = 3$  auf  $|\mathcal{C}| \approx N/18$  für  $n_Q = 20$ , d. h. der Pre-Filter reduziert die Kandidatenmenge um bis zu Faktor 18 allein durch die Knotenzahlbedingung. In Kombination mit der Kantenanzahlbedingung (Lemma 2) ist die tatsächliche Reduktion empirisch noch deutlich stärker, insbesondere für Query-Netzwerke mit hoher Kantendichte.

## 5.5 Visualisierung 3: Skalierungsverhalten der Suchzeit

**Beschreibung:** Die Kurve für  $K = 10.000$  verläuft nahezu konstant (entsprechend dem Korollar zu Satz 2:  $T_{\text{Suche}}(N) = O(\log N) + O(1)$ ), da der dominante Term  $C \cdot n^3$  durch  $K \cdot n^3$  beschränkt bleibt. Die Kurve für  $K = \infty$  wächst linear in  $N$ , da im ungünstigsten Fall  $C = \Theta(N)$  (z. B. für sehr kleine  $n_Q$ , vgl. Abbildung 4). Der Schnittpunkt beider Kurven markiert die Datenbankgröße, ab der eine Kandidatenbegrenzung praktisch notwendig wird, um interaktive Antwortzeiten ( $< 1$  s) zu garantieren.

## 5.6 Visualisierung 4: Trefferverteilung nach Match-Typ

**Beschreibung:** Für kleine  $n_Q$  (z. B.  $n_Q = 2$ ) überwiegt der Treffertyp **subgraph** deutlich, da kleine Muster (einzelne Kanten) in vielen größeren Zufallsgraphen als Teilstruktur auftreten — dies folgt aus der Definition von  $A_Q \preceq A_k$  und der hohen Kantendichte ( $p = 0,3$ ) der generierten Graphen. Für  $n_Q \rightarrow n_{\max} = 20$  sinkt die Trefferzahl insgesamt (Korollar zu Lemma 2: weniger Kandidaten mit  $n_k \geq n_Q$ ), und der Anteil von **exact**-Treffern (Übereinstimmung bis auf Rotation) bleibt verschwindend gering, da die Wahrscheinlichkeit zweier identischer Zufallsgraphen mit  $n = 20$  vernachlässigbar ist ( $2^{-\binom{20}{2} \cdot p \dots}$ , kombinatorisch verschwindend).




Abbildung 4: Anzahl verbleibender Kandidaten  $|\mathcal{C}(Q, \mathcal{D})|$  nach Pre-Filterung in Abhängigkeit von  $n_Q$  (Query-Knotenzahl), für  $N = 1.000.000$ , doppelt-logarithmische Skala.

## 5.7 Diskussion

Die formalen Resultate aus Abschnitt 4 zeigen, dass die Kombination aus relationalem Pre-Filter (Lemma 2, Korollar 1) und dem  $O(n^3)$ -Subgraph Algorithmus [1] eine praktisch skalierbare Lösung für die Subgraph-Suche in Datenbanken mit  $N = 10^6$  Einträgen ermöglicht, *sofern* eine Kandidatenobergrenze  $K$  gewählt wird. Diese Obergrenze erkaufte sich Konstantzeit-Verhalten (im Sinne von  $N$ ) jedoch um den Preis einer potentiellen Unvollständigkeit (Verlust der Garantie aus Satz 3). Abschnitt 8 adressiert dieses Spannungsfeld.

## 6 Experimenteller Vergleich

Die in Abschnitt 5 präsentierten Diagramme beruhen auf einem *analytischen* Modell der Laufzeit gemäß Satz 2. Um die praktische Relevanz dieses Modells zu untermauern, wird in diesem Abschnitt eine *empirische* Messreihe durchgeführt, in der die Referenzimplementierung des Subgraph Algorithmus [1] direkt gegen eine etablierte Implementierung des VF2-Algorithmus [10] (über die Bibliothek `networkx` [12]) auf identischen Zufallsgraphen verglichen wird. Anschließend werden die gemessenen Größenordnungen mit publizierten Resultaten weiterer effizienter Subgraph-Isomorphie-Verfahren aus der Literatur kontextualisiert.

### 6.1 Versuchsanordnung

**Definition 8** (Subgraph-Relation  $\preceq$ , Referenz).  $\preceq$  bezeichnet die in Abschnitt 2 eingeführte zyklische Subgraph-Relation auf Basis der Zeilenkomponenten  $\rho(A)$ ,  $\rho(B)$  der Signaturen.




Abbildung 5: Geschätzte Suchzeit  $T_{\text{Suche}}$  als Funktion der Datenbankgröße  $N$ , für festes Kandidatenlimit  $K = 10.000$  und  $K = \infty$  (volle Pipeline), gemäß Satz 2.

**Definition 9** (Vergleichsexperiment). Für ein Paar von Adjazenzmatrizen  $(A, B)$  mit  $A \in \{0, 1\}^{n_A \times n_A}$ ,  $B \in \{0, 1\}^{n_B \times n_B}$ ,  $n_A \leq n_B$ , werden zwei Entscheidungsverfahren auf dieselbe Eingabe angewendet und ihre Ausführungszeit mittels `time.perf_counter()` gemessen:

- **Subgraph Algorithmus** (Referenzimplementierung gemäß den drei Schritten aus Abschnitt 2, reines Python mit `numpy`-Signaturberechnung und dynamischer LCS-Tabelle).
- **VF2** [10], instanziiert über `networkx.algorithms.isomorphism.DiGraphMatcher(B, A).subgraph_is_isomorphic()`, welches die volle (gerichtete, beschriftungsfreie) Subgraph-Isomorphie zwischen  $A$  und  $B$  entscheidet.

**Bemerkung 3.** Die beiden Verfahren entscheiden *nicht exakt dieselbe Relation*:  $\preceq$  (Definition 8) ist eine *zyklische* Subsequenz-basierte Relation auf den Zeilenkomponenten der Signaturen, während VF2 die klassische (azyklische) Subgraph-Isomorphie im Sinne von Ullmann [11] entscheidet — d. h. Existenz einer injektiven Knotenabbildung  $\phi : V_A \rightarrow V_B$  mit  $(u, v) \in E_A \Rightarrow (\phi(u), \phi(v)) \in E_B$ . Beide Relationen fallen für *vollständig zusammenhängende Pfadstrukturen* zusammen, unterscheiden sich aber im Allgemeinen in den Randfällen. Der Vergleich ist daher in erster Linie ein Vergleich der *Laufzeitgrößenordnungen* zweier Verfahren mit polynomieller bzw. (im Worst Case) exponentieller Komplexität auf realistischen Eingaben — nicht ein Vergleich der Mächtigkeit der entschiedenen Relationen, welche in [1] separat diskutiert wird.

Für das erste Experiment wird  $n_A = 5$  fixiert und  $A$  einmalig als Erdős-Rényi-Graph  $G(5, 0.3)$  gezogen. Für  $n_B = 5, \dots, 18$  werden jeweils 8 unabhängige Kandidaten  $B \sim G(n_B, 0.3)$  erzeugt und beide Verfahren angewendet; es werden Mittelwert und




Abbildung 6: Verteilung der Treffertypen (**exact** vs. **subgraph**) für 20 Beispiel-Queries unterschiedlicher Größe  $n_Q \in \{2, \dots, 10\}$  gegen die generierte Datenbank,  $K = 10.000$ .

Standardabweichung der Laufzeit über die 8 Wiederholungen berichtet. Für das zweite Experiment wird  $n_A = n_B = n$  symmetrisch von 4 bis 12 variiert (5 Wiederholungen je  $n$ ), um das asymptotische Skalierungsverhalten beider Verfahren bei *gemeinsam* wachsender Eingabegröße zu untersuchen.

## 6.2 Ergebnis 1: Laufzeitvergleich bei festem $n_A = 5$ , wachsendem $n_B$

Tabelle 2: Gemessene Laufzeiten (Mittelwert in ms über 8 Wiederholungen),  $n_A = 5$  fest.

| $n_B$ | $T_{\text{Sub}}$ (ms) | $T_{\text{VF2}}$ (ms) | Speedup $T_{\text{VF2}}/T_{\text{Sub}}$ |
|-------|-----------------------|-----------------------|-----------------------------------------|
| 5     | 0,092                 | 0,428                 | 4,67                                    |
| 6     | 0,118                 | 0,352                 | 2,98                                    |
| 7     | 0,200                 | 0,556                 | 2,78                                    |
| 8     | 0,202                 | 0,564                 | 2,79                                    |
| 9     | 0,414                 | 0,934                 | 2,26                                    |
| 10    | 0,365                 | 1,204                 | 3,30                                    |
| 11    | 0,482                 | 1,263                 | 2,62                                    |
| 12    | 0,562                 | 1,729                 | 3,08                                    |
| 13    | 0,684                 | 1,318                 | 1,93                                    |
| 14    | 0,755                 | 0,836                 | 1,11                                    |
| 15    | 0,837                 | 0,927                 | 1,11                                    |
| 16    | 1,015                 | 1,099                 | 1,08                                    |
| 17    | 1,146                 | 0,947                 | 0,83                                    |
| 18    | 1,271                 | 1,037                 | 0,82                                    |

**Beschreibung und Interpretation:** Für  $n_B \in [5, 13]$  ist der Subgraph Algorithmus um den Faktor 1,9 bis 4,7 schneller als VF2 — die zugrunde liegende Operation (Sig-




Abbildung 7: Gemessene Laufzeit (Mittelwert über 8 Wiederholungen, Fehlerbalken = Standardabweichung) des Subgraph Algorithmus und von VF2 in Abhängigkeit von  $n_B$ , bei festem  $n_A = 5$ , logarithmische  $y$ -Achse.

naturberechnung plus  $n_B$  LCS-Vergleiche der Länge  $\leq n_B$ ) hat einen kleinen, gut vorher-sagbaren Konstantenfaktor, während VF2 trotz seiner effizienten Kandidaten-Pruning-Heuristiken pro Knotenpaar einen größeren Overhead durch den allgemeineren Isomorphie-Mechanismus (Konsistenz- und Lookahead-Prüfungen [10]) trägt. Für  $n_B \geq 14$  kehrt sich das Verhältnis um (Speedup  $< 1$ ): Die LCS-Tabelle des Subgraph Algorithmus wächst quadratisch in  $n_B$  und wird  $n_B$ -mal (für jede Rotation) neu berechnet, also  $O(n_B^3)$  Gesamtaufwand, während VF2 bei den hier verwendeten dichten Zufallsgraphen ( $p = 0,3$ ) durch sein Pruning häufig *sehr früh* terminiert (entweder weil sofort ein Match gefunden wird oder weil ein Konsistenzbruch in den ersten Rekursionsschritten erkannt wird) — der Erwartungswert der von VF2 tatsächlich besuchten Suchbaumknoten bleibt für  $G(n, p)$  mit konstantem  $p$  empirisch klein, obwohl die Worst-Case-Schranke von VF2 bei  $O(n!n)$  liegt [10].

Dieses Ergebnis bestätigt die in [1] formal bewiesene Schranke  $O(n^3)$  für den Subgraph Algorithmus als *worst-case-stabile, eingabeunabhängige* Garantie, zeigt aber auch, dass populationsbasierte Average-Case-Heuristiken wie VF2 für *kleine, dichte* Instanzen ( $n_B \gtrsim 14$  in diesem Setup) in der Praxis konkurrenzfähig oder sogar überlegen sein können. Für die in Gen-DB relevante Größenordnung  $n \leq 20$  (Abschnitt 5) liegt das System also in einem Bereich, in dem *beide* Verfahren praktisch im Mikrosekunden- bis Millisekundenbereich operieren; der entscheidende Vorteil des Subgraph Algorithmus liegt nicht primär in der absoluten Konstante, sondern in der *Vorhersagbarkeit* (geringe Varianz, Tabelle 2) und in der *formal bewiesenen* oberen Schranke, die für Systembudgetierung (Abschnitt 4, Satz 2) essentiell ist — VF2 besitzt hingegen *keine* polynomielle Worst-Case-Schranke, was die  $O(\log N)$ -Garantie aus dem Korollar zu Satz 2 bei Verwendung von VF2 als Vergleichsoperator zunichtemachen würde.




Abbildung 8: Speedup-Faktor  $T_{VF2}/T_{Sub}$  als Funktion von  $n_B$  (gestrichelte Linie bei 1,0: Gleichstand).

### 6.3 Der Subgraph Algorithmus für $n_B \geq 14$

Die in Abbildung 8 sichtbare Umkehrung des Speedup-Verhältnisses bei  $n_B \approx 14$  erscheint auf den ersten Blick im Widerspruch zur in Satz 1 bewiesenen  $O(n^3)$ -Schranke des Subgraph Algorithmus gegenüber der  $O(n!n)$ -Worst-Case-Schranke von VF2 [10] zu stehen. Tatsächlich handelt es sich nicht um einen Widerspruch, sondern um den Unterschied zwischen *worst-case-treuer Ausschöpfung* und *durchschnittsfallbasierter Terminierung*, der im Folgenden in vier Ursachen aufgeschlüsselt wird.

1. **Vollständige LCS-Tabellenkonstruktion pro Rotation, ohne Early-Exit.** Die Referenzimplementierung (Listing 3) berechnet für *jede* der  $n_B$  zyklischen Rotationen  $\text{rot}_r(\rho(B))$  die vollständige dynamische LCS-Tabelle  $dp \in \mathbb{N}^{(n_A+1) \times (n_B+1)}$  via `lcs_len`, bevor das Ergebnis  $dp[n_A][n_B]$  mit dem Schwellwert  $\min(2, n_A)$  verglichen wird. Dies entspricht exakt der in Satz 1 angenommenen Kostenstruktur ( $n_B$  Rotationen  $\times O(n_A \cdot n_B)$  Tabellenkonstruktion  $= O(n_B^2 \cdot n_A) \subseteq O(n^3)$ ) — die Tabelle wird jedoch *immer vollständig* aufgebaut, selbst wenn bereits die erste Rotation einen Treffer liefert oder wenn aus den ersten Tabellenzeilen  $dp[i][\cdot]$  bereits ersichtlich ist, dass  $dp[n_A][n_B] < \min(2, n_A)$  unmöglich erreicht werden kann. Die bewiesene Schranke wird damit nicht nur als *obere*, sondern de facto als *tatsächliche* Laufzeit realisiert:  $T_{Sub}(n) = \Theta(n^3)$  statt  $O(n^3)$ .
2. **Average-Case-Pruning von VF2 terminiert auf  $G(n, 0, 3)$  empirisch sehr früh.** Der VF2-Algorithmus [10] baut eine Teilabbildung  $\phi$  knotenweise auf und prüft nach jedem Erweiterungsschritt drei Konsistenzbedingungen (Syntax-, Semantik- und Lookahead-Regeln 0, 1, 2). Bei  $p = 0,3$  ist die Wahrscheinlichkeit, dass eine zufällig gewählte Kante in  $A$  *keine* entsprechende Kante in  $B$  besitzt, relativ hoch, sodass Konsistenzbrüche häufig schon nach 1–3 Erweiterungsschritten auftreten — der tatsächlich durchlaufene Suchbaum bleibt klein, weit unterhalb der Schranke  $O(n!n)$ . Dieser Effekt ist in der Literatur als *typische* Eigenschaft von

Backtracking-Algorithmen auf zufälligen, hinreichend dichten Graphen dokumentiert [14, 13]: Die mittlere Anzahl besuchter Suchbaumknoten wächst für  $G(n, p)$  mit konstantem  $p > 0$  häufig nur polynomiell oder sogar sublinear in  $n$ , obwohl die Worst-Case-Schranke superpolynomiell ist.

### 3. Implementierungs-Overhead: reines Python vs. optimierte Bibliothek.

Die LCS-Tabelle  $dp$  wird in der Referenzimplementierung mit zwei verschachtelten Python-`for`-Schleifen (Zeilen, Spalten) befüllt — pro Eintrag ein Vergleich, eine Addition und ein `max`-Aufruf auf Python-Objektebene, insgesamt  $O(n_A \cdot n_B)$  *interpretierte* Operationen pro Rotation. Demgegenüber ist `networkx.algorithms.isomorphism.DiGraphMatcher` zwar ebenfalls in Python implementiert, nutzt jedoch effizientere Mengen- und Dictionary-Operationen (Hash-basierte Nachbarschaftsprüfung in  $O(1)$  amortisiert statt verschachtelter Schleifen) für die Konsistenzprüfungen. Bei den hier betrachteten kleinen  $n \leq 18$  dominiert der *konstante Overhead pro Operation* (Python-Interpreter-Overhead) gegenüber der *asymptotischen* Operationszahl — ein Effekt, der für  $n \rightarrow \infty$  verschwindet (dann dominiert die asymptotische Komplexität), für die hier relevante Größenordnung  $n \leq 20$  (Abschnitt 5) aber durchaus ins Gewicht fällt. Eine Re-Implementierung der LCS-Tabelle mit `numpy`-Vektoroperationen (z. B. diagonalenweise Vektorisierung der DP-Rekursion) oder mittels `numba-JIT`-Kompilierung würde den konstanten Faktor von  $T_{\text{Sub}}(n)$  deutlich senken, ohne die asymptotische  $O(n^3)$ -Schranke zu verändern (Abschnitt 8.3.18, Punkt “Implementierungssprache”).

4. **Strukturelle Konsequenz, kein Widerspruch zur formalen Garantie.** Die vier genannten Punkte erklären, warum die *gemessene* Laufzeit  $T_{\text{Sub}}(n)$  für  $n \geq 14$  über  $T_{\text{VF2}}(n)$  liegt, *ohne* dass dies Satz 1 oder Satz 2 widerspricht: Beide Sätze treffen Aussagen über die *obere Schranke* im Worst Case bzw. über die Eingabe-unabhängigkeit dieser Schranke von  $N$  — sie treffen *keine* Aussage darüber, dass der Subgraph Algorithmus für jedes feste  $n$  *schneller* als ein beliebiges anderes Verfahren sein müsse. Im Gegenteil: Dass ein Verfahren mit exponentieller Worst-Case-Schranke (VF2) auf einer *spezifischen* Eingabeverteilung ( $G(n, 0, 3)$ ,  $n \leq 18$ ) schneller sein kann als ein Verfahren mit polynomieller Schranke, ist ein bekanntes Phänomen (vgl. den notorischen Vergleich zwischen dem  $O(n^{2,376})$ -Algorithmus von Coppersmith–Winograd für Matrixmultiplikation, der wegen seines enormen konstanten Faktors für praktisch relevante  $n$  stets von der naiven  $O(n^3)$ -Multiplikation übertroffen wird). Für die Gen-DB-Pipeline (Satz 2) bedeutet dies konkret: Die *formale* Garantie  $T_{\text{Suche}}(N) = O(\log N) + O(1)$  bleibt unabhängig von diesen konstanten Faktoren gültig, da sie nur die *Größenordnung* in  $N$  und  $n_{\text{max}}$  betrifft; für die *absolute* Performanz bei festem, kleinem  $n$  ist jedoch die in Abschnitt 8.3.10 vorgeschlagene Hybridstrategie die direkte praktische Konsequenz dieser Ursachenanalyse.

**Bemerkung 4** (Abgrenzung: Beweis vs. Implementierung). Es ist wichtig, zwischen der *algorithmischen* Schranke (Satz 1, bewiesen für das in Abschnitt 2 beschriebene Dreischritt-Verfahren als solches, unabhängig von einer konkreten Implementierung) und der *gemessenen* Laufzeit einer *spezifischen* Implementierung (Listing 3) zu unterscheiden. Punkt 1 und 3 dieser Ursachenanalyse betreffen ausschließlich die *Implementierung*: Eine Version mit Early-Exit (Abbruch der Rotationen, sobald  $dp[n_A][n_B] \geq \min(2, n_A)$  erreicht ist) und vektorisierter DP-Tabelle würde  $T_{\text{Sub}}(n)$  im Best Case auf  $\Omega(n^2)$  (eine einzige

erfolgreiche Rotation) reduzieren, ohne die *obere* Schranke  $O(n^3)$  zu verändern — die in Tabelle 2 berichteten Werte stellen also tendenziell eine *obere Abschätzung* der praktisch erreichbaren Laufzeit des Subgraph Algorithmus dar, während die VF2-Werte bereits eine *ausgereifte, optimierte* Implementierung widerspiegeln. Ein faires Replikat dieses Experiments mit einer entsprechend optimierten Subgraph Algorithmus-Implementierung ist Teil von Abschnitt 8.3.18.




Abbildung 9: Gemessene Laufzeit beider Verfahren bei gemeinsam wachsendem  $n = n_A = n_B$  (5 Wiederholungen je  $n$ ), zusammen mit einer auf den ersten Messpunkt skalierten  $O(n^3)$ -Referenzkurve für den Subgraph Algorithmus.

**Beschreibung:** Die gemessene Laufzeitkurve des Subgraph Algorithmus folgt der eingezeichneten  $O(n^3)$ -Referenz erkennbar enger als eine lineare oder quadratische Kurve es täte, was die in Satz 1 bewiesene kubische Schranke empirisch stützt (für  $n = 4 \rightarrow 12$ , also Faktor 3, wächst  $T_{\text{Sub}}$  von 0,055 ms auf 1,309 ms, also um den Faktor  $\approx 23,8$ ;  $3^3 = 27$  liegt in derselben Größenordnung, die Abweichung erklärt sich durch den additiven  $O(n^2)$ -Signaturanteil, der bei kleinem  $n$  relativ stärker wiegt). Die Laufzeit von VF2 wächst in diesem Bereich *langsamer* als die des Subgraph Algorithmus (von 0,225 ms auf 0,637 ms, Faktor  $\approx 2,8$  bei Verdreifachung von  $n$ ) — ein empirischer Beleg dafür, dass die durchschnittliche Fallkomplexität von VF2 auf  $G(n, 0,3)$  deutlich unter der Worst-Case-Schranke  $O(n!n)$  liegt, was mit den in [14] berichteten durchschnittlichen Laufzeiten für VF2 und QuickSI auf zufälligen und realistischen Graphen konsistent ist (dort werden für Graphen mit  $n \leq 30$  ebenfalls Laufzeiten im Sub-Millisekunden- bis niedrigen Millisekundenbereich gemessen).

## 6.4 Einordnung in die Literatur effizienter Subgraph-Isomorphie-Verfahren

Tabelle 3 fasst die in dieser Arbeit gemessenen Größenordnungen zusammen mit publizierten Charakterisierungen weiterer etablierter Algorithmen für (Teil-)Graphisomorphie

und Subgraph-Suche. Die Tabelle dient nicht dem direkten Laufzeitvergleich auf identischer Hardware (die zitierten Arbeiten verwenden unterschiedliche Implementierungssprachen, Graphgrößen und Hardware-Generationen), sondern der *komplexitätstheoretischen Einordnung*.

Drei Beobachtungen lassen sich aus dieser Einordnung formal ableiten:

1. **Komplexitätsklasse:** Der Subgraph Algorithmus ist das einzige der in Tabelle 3 aufgeführten Verfahren mit einer *unbedingten* polynomiellen Worst-Case-Schranke ( $O(n^3)$ , Satz 1). Alle übrigen Verfahren lösen das (im Allgemeinen NP-vollständige bzw. GI-vollständige) Subgraph-Isomorphie-Problem und besitzen daher worst-case zumindest superpolynomielle Schranken; ihre praktische Effizienz beruht auf Heuristiken (Pruning, Knotenordnung, Nachbarschaftssignaturen), die im Average Case, aber nicht im Worst Case greifen. Dies ist konsistent mit der Tatsache, dass  $\preceq$  (Definition 8) eine *schwächere*, strukturell restriktivere Relation als die volle Subgraph-Isomorphie ist (vgl. Bemerkung zu Definition 9) — die polynomielle Schranke wird also durch eine Einschränkung des Relationsbegriffs erkaufte, was formal die in [1] diskutierte SETH-basierte Optimalitätsanalyse motiviert.
2. **Praktische Konsequenz für Satz 2:** Da  $T_{\text{Suche}}(N, C, n) = O(\log N + C) + O(C \cdot n^3)$  die Komplexität *eines einzelnen* Subgraph-Vergleichs als  $O(n^3)$  in die Pipeline einsetzt, wäre eine Substitution durch VF2, Ullmann, RI oder QuickSI formal nicht mit demselben Korollar (konstante Suchzeit unabhängig von  $N$ ) vereinbar, da  $O(n^3)$  durch eine worst-case-exponentielle Schranke ersetzt würde. Die empirisch hohe Average-Case-Effizienz von VF2/RI/QuickSI auf realistischen Graphen (Ergebnis 2, sowie [14, 13]) bedeutet zwar, dass eine solche Substitution *im Mittel* ähnlich performant sein könnte, jedoch ohne die formale Garantie aus Satz 2 — ein Datenbanksystem mit harten Latenzanforderungen (SLA) profitiert daher strukturell vom Subgraph Algorithmus.
3. **Komplementarität statt Konkurrenz:** Die in [13, 14] beschriebenen Optimierungen (Knotenordnung nach Seltenheit, Nachbarschaftssignaturen) sind *orthogonal* zum Subgraph Algorithmus und könnten gemäß Abschnitt 8 (z.B. R-Baum-Pre-Filter) auf die *Pre-Filter-Stufe* der Gen-DB-Pipeline angewendet werden, während der eigentliche Vergleich der gefilterten Kandidaten durch den Subgraph Algorithmus mit garantierter  $O(n^3)$ -Schranke erfolgt. Insofern stehen die hier verglichenen Verfahren nicht in direkter Konkurrenz, sondern adressieren unterschiedliche Stufen derselben Pipeline (Kandidatenreduktion vs. finaler Strukturvergleich).

## 7 Experimentelle Untersuchung der Parallelisierung

Die bisherigen Abschnitte haben die Such-Pipeline von Gen-DB formal analysiert (Abschnitt 4), an einer synthetischen Datenbank mit einer Million Netzwerken statistisch charakterisiert (Abschnitt 5) und den Subgraph Algorithmus in Einzelvergleichen gegen VF2 gemessen (Abschnitt 6). Offen geblieben ist die Frage, wie sich die *gesamte* Suche verhält, wenn der dominierende Kostenterm  $O(C \cdot n^3)$  aus Satz 2 auf mehrere Prozesse verteilt wird. Dieser Abschnitt beantwortet sie empirisch: Er beschreibt die in Gen-DB implementierte parallele Ausführung der Kandidatenvergleiche, den Aufbau eines reproduzierbaren Experiments mit 1, 2 und 3 Worker-Prozessen und wertet die Messergebnisse anhand von vier Diagrammen und zwei Tabellen aus.

Tabelle 3: Einordnung des Subgraph Algorithmus relativ zu etablierten Verfahren.

| Verfahren                | Worst-Case-Komplexität                                                                  | Entschiedene Relation                                                 | Charakteristik                                                                                                         |
|--------------------------|-----------------------------------------------------------------------------------------|-----------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------|
| Subgraph Algorithmus [1] | $O(n^3)$ , bedingt optimal unter SETH [2]                                               | zyklische LCS-basierte Subsequenz-Relation $\preceq$                  | polynomiell, eingebeunabhängige Schranke, geringe Varianz (Tabelle 2)                                                  |
| Ullmann [11]             | $O(n^n)$ bzw. $O(n_A! \cdot n_B^A)$ (naiv, mit Pruning praktisch geringer)              | (Sub-)Graphisomorphie, Knotenbijektion $\phi$                         | historischer Referenzalgorithmus, Backtracking mit Refinement                                                          |
| VF2 [10]                 | $O(n! \cdot n)$ Worst Case, oft sub-exponentiell in der Praxis                          | (Sub-)Graphisomorphie 0, 1, 2; in dieser Arbeit gemessen, vgl. Tab. 2 | Lookahead-Pruning (Schemata für biologische Netzwerke (PPI, Metabolismus) optimierte Knotenordnung                     |
| RI / RI-DS [13]          | worst-case exponentiell, empirisch deutlich schneller als VF2 auf Bioinformatik-Graphen | (Sub-)Graphisomorphie                                                 |                                                                                                                        |
| QuickSI [14]             | worst-case exponentiell                                                                 | Subgraph-Isomorphie (Pattern Matching)                                | Häufigkeits-basierte Kantenordnung, in [14] ca. 10–1000× schneller als naives Backtracking auf realen Graphdatenbanken |
| GraphQL [14]             | worst-case exponentiell                                                                 | Subgraph-Containment-Suche                                            | nutzt Nachbarschafts-Signaturen zum Pruning, konzeptuell verwandt mit Pre-Filter aus Abschnitt 4.2                     |

## 7.1 Fragestellung und Hypothesen

Nach Satz 2 setzt sich die Suchzeit aus dem Pre-Filter  $O(\log N + C)$  und den  $C$  strukturellen Vergleichen  $O(C \cdot n^3)$  zusammen. Da die Vergleiche für verschiedene Kandidaten voneinander unabhängig sind, lässt sich die Laufzeit einer Parallelisierung über  $p$  Worker-Prozesse durch

$$T_{\text{parallel}}(C, n, p) = O\left(\frac{C}{p} \cdot n^3\right) + O(n^3)$$

modellieren. Das Experiment prüft drei daraus abgeleitete Hypothesen:

- H1** Die Gesamtzeit einer Suche sinkt bei Verdopplung der Worker-Zahl von 1 auf 2 annähernd um den Faktor 2, weil der parallelisierbare Vergleichsanteil die Laufzeit dominiert.
- H2** Mehr Worker-Prozesse als logische Prozessoren der Maschine bringen keinen weiteren Gewinn, da die Vergleiche CPU-gebunden sind und keine zusätzliche Rechenkapazität entsteht.
- H3** Die Suchzeit wächst, unabhängig von der Worker-Zahl, annähernd linear mit der Kandidatenzahl  $C$ , wie es der Term  $O(C \cdot n^3)$  bei beschränktem  $n \leq 20$  erwarten lässt.

## 7.2 Implementierung der parallelen Suche

Die Suche ist in der Funktion `search_subgraph` des Moduls `crud` umgesetzt und läuft in drei Phasen. Zuerst liest eine einzige SQL-Abfrage alle Netzwerke, die die notwendigen Bedingungen  $n_k \geq n_Q$  und  $m_k \geq m_Q$  des Pre-Filters (Abschnitt 4.2) erfüllen, zusammen mit ihren Adjazenzmatrizen. Danach übergibt `compare_many` aus dem Modul `subgraph_executor` die Matrizen an einen `ProcessPoolExecutor`, dessen Größe über die Konfigurationsvariable `SUBGRAPH_MAX_WORKERS` bestimmt wird. Jeder Worker-Prozess erzeugt genau eine Instanz des Subgraph Algorithmus und ruft für ein Paar aus Query  $A$  und Kandidat  $B$  die Methode `compare_graphs(A, B)` auf. Weil der Algorithmus in reinem Python implementiert und CPU-gebunden ist, werden Prozesse statt Threads verwendet; der Global Interpreter Lock würde Threads sonst serialisieren. Um den Kommunikationsaufwand zwischen Hauptprozess und Workern zu verringern, werden die Kandidaten in Blöcken (*Chunks*) von 256 Vergleichen pro Task verteilt. Schließlich baut der Hauptprozess aus den Entscheidungen `keep_B` und `equal_keep_*` die Trefferliste auf.

Zwei Eigenschaften dieser Implementierung sind für die Auswertung wichtig. Erstens enthält die aktuelle Fassung *kein* Kandidatenlimit  $K$ ; alle Kandidaten des Pre-Filters werden verglichen, sodass Satz 3 mit  $K = \infty$  gilt und die gemessenen Zeiten einer vollständigen Suche entsprechen. Zweitens sind nur die Vergleiche parallelisiert. Das Lesen der Kandidaten aus PostgreSQL, die Übertragung der Matrizen an die Worker und der Aufbau der Trefferliste laufen im Hauptprozess und bilden den seriellen Anteil der Suche.

## 7.3 Versuchsaufbau

Das Experiment wird durch das Skript `src/experiment_search_workers.py` gesteuert. Es wählt mit festem Seed zufällig Netzwerke aus der Datenbank und verwendet sie als Suchanfragen. Um Verzerrungen durch zu kleine Muster zu vermeiden, besitzen alle

Queries mindestens 15 Knoten. Für jede Worker-Anzahl werden *dieselben* Anfragen in derselben Reihenfolge über `crud.search_subgraph` ausgeführt, sodass die Zeiten als gepaarte Messungen direkt vergleichbar sind. Vor jeder Messreihe wird der Prozess-Pool neu erzeugt und alle Worker werden vorab gestartet, damit die Startzeit der Prozesse nicht in die Messung eingeht. Eine zusätzliche Aufwärmanfrage pro Worker-Anzahl wird verworfen, um Caching-Effekte der Datenbank auszugleichen. Gemessen wird die Wanduhrzeit der gesamten Funktion mit `time.perf_counter()`; sie umfasst somit Datenbankabfrage, Vergleiche, Prozesskommunikation und Aufbau der Trefferliste. Nach jeder Anfrage schreibt das Skript die bisherigen Messwerte in eine JSON-Datei, sodass ein Abbruch keine Daten verliert.

Tabelle 4: Parameter und Umgebung des Experiments.

| Parameter       | Wert                                                       |
|-----------------|------------------------------------------------------------|
| Datenbank       | 1.000.002 Netzwerke (davon 333.500 mit $n_k \geq 15$ )     |
| Anzahl Anfragen | 6 je Worker-Anzahl, identisch über alle Reihen             |
| Query-Auswahl   | zufällig aus der Datenbank, $n_Q \geq 15$ , Seed 42        |
| Worker-Anzahlen | $p \in \{1, 2, 3\}$                                        |
| Aufwärmanfragen | 1 je Worker-Anzahl (verworfen)                             |
| Chunk-Größe     | 256 Vergleiche pro Task                                    |
| Kandidatenlimit | keines                                                     |
| Rechner         | 2 logische Prozessoren, PostgreSQL 16 auf demselben System |
| Software        | Python 3.13, Linux                                         |

Die ursprüngliche Voreinstellung des Skripts sieht 50 Anfragen je Worker-Anzahl vor. Da eine einzelne Suche auf dem verwendeten Rechner bis zu rund 400 Sekunden dauert, hätte diese Konfiguration mehrere Stunden benötigt; die Messreihe wurde deshalb auf 6 Anfragen begrenzt (Aufruf: `python src/experiment_search_workers.py -queries 6 -workers 1 2 3`). Die Folgen dieser Entscheidung für die Aussagekraft werden in Abschnitt 7.7 diskutiert.

## 7.4 Metriken

Für eine Worker-Anzahl  $p$  bezeichne  $T(p)$  die Summe der Antwortzeiten aller  $Q = 6$  Anfragen und  $C_\Sigma = \sum_q C_q$  die Summe der Kandidatenzahlen.

**Definition 10** (Speedup, Effizienz, Durchsatz). Der *Speedup* ist  $S(p) = T(1)/T(p)$ , die *parallele Effizienz*  $E(p) = S(p)/p$ . Der *Durchsatz* ist  $\Theta(p) = C_\Sigma/T(p)$  in Kandidaten pro Sekunde, und die *Kosten pro Kandidat* sind  $\kappa(p) = T(p)/C_\Sigma$ .

Aus dem Speedup lässt sich mit dem Gesetz von Amdahl der nicht parallelisierte Zeitanteil  $f$  abschätzen. Gilt  $T(p) = T(1)(f + \frac{1-f}{p})$ , so folgt

$$f = \frac{1/S(p) - 1/p}{1 - 1/p}.$$

Diese Abschätzung ist nur sinnvoll, solange  $p$  die Zahl der verfügbaren Prozessoren nicht übersteigt.

## 7.5 Ergebnisse

### 7.5.1 Die untersuchten Anfragen

Tabelle 5 zeigt die sechs ausgewählten Anfragen. Die Kandidatenzahl  $C$  schwankt um mehr als den Faktor 5, zwischen 62.064 und 325.964. Sie ergibt sich aus der Vorauswahl: Bei gleichverteilter Knotenzahl  $n_k \in \{3, \dots, 20\}$  besitzen 333.500 der 1.000.002 Netzwerke mindestens 15 Knoten, und für Queries mit 15 Knoten entscheidet nur noch die Kantenbedingung  $m_k \geq m_Q$  über den Rest. Bei der Anfrage 5 mit  $m_Q = 56$  Kanten erfüllen 97,7 % dieser Netzwerke die Kantenbedingung, bei der Anfrage 1 mit  $m_Q = 68$  noch 82,6 %. Die Anfragen 2 und 6 mit 19 Knoten werden zusätzlich von der Knotenbedingung stark eingeschränkt, da nur Netzwerke mit 19 oder 20 Knoten in Frage kommen. Der Pre-Filter reduziert den Suchraum damit auf 6,2 % bis 32,6 % der Datenbank.

Die Trefferzahlen sind mit 1 bis 7 minimal. Da jede Query selbst ein Netzwerk der Datenbank ist und die Kandidatenmenge dieses Netzwerk enthält, ist zu erwarten, dass der einzelne Treffer der Anfragen mit genau einem Ergebnis dem Query-Netzwerk selbst entspricht. Netzwerke mit mindestens 15 Knoten und der Kantendichte  $p = 0,3$  sind also in anderen Zufallsnetzwerken praktisch nie als Teilstruktur enthalten. Dieser Befund steht im Gegensatz zum Serverprotokoll in Abschnitt 4.6, bei dem nahezu alle Kandidaten Treffer waren; die Trefferquote hängt, wie dort bereits vermerkt, stark von der konkreten Query ab. Für die Laufzeitmessung ist das hier günstig, denn der Aufbau der Trefferliste im Hauptprozess ist vernachlässigbar, und die gemessene Zeit wird fast vollständig von Vorauswahl und Vergleichen bestimmt.

Tabelle 5: Eigenschaften der sechs Suchanfragen und Suchzeiten  $t_p$  in Sekunden bei  $p$  Workern.

| Nr. | Netzwerk-ID | $n_Q$ | $m_Q$ | $C$     | Treffer | $t_1$ | $t_2$ | $t_3$ | $S(2)$ |
|-----|-------------|-------|-------|---------|---------|-------|-------|-------|--------|
| 1   | 654454      | 15    | 68    | 275.420 | 1       | 360,8 | 193,2 | 198,4 | 1,87   |
| 2   | 773650      | 19    | 107   | 62.064  | 1       | 70,0  | 36,7  | 40,6  | 1,91   |
| 3   | 432492      | 16    | 77    | 221.027 | 1       | 294,9 | 153,0 | 169,4 | 1,93   |
| 4   | 858614      | 15    | 70    | 263.668 | 3       | 354,9 | 185,8 | 209,2 | 1,91   |
| 5   | 438514      | 15    | 56    | 325.964 | 7       | 403,2 | 212,0 | 224,6 | 1,90   |
| 6   | 88827       | 19    | 95    | 100.911 | 1       | 120,4 | 62,4  | 65,4  | 1,93   |

### 7.5.2 Gesamtzeit und Speedup

Abbildung 10 zeigt als Balkendiagramm die Summe der Antwortzeiten aller sechs Anfragen in Minuten, getrennt nach Worker-Anzahl. Über jedem Balken steht der Speedup relativ zur Messreihe mit einem Worker. Mit einem Worker benötigt die Suche zusammen 1604 Sekunden, das sind rund 26,7 Minuten. Mit zwei Workern sinkt dieser Wert auf 843 Sekunden (rund 14,1 Minuten), was einem Speedup von  $S(2) = 1,90$  und einer Effizienz von  $E(2) = 0,95$  entspricht. Der dritte Balken liegt bei 908 Sekunden (rund 15,1 Minuten) und damit *über* dem Balken für zwei Worker; der Speedup fällt auf  $S(3) = 1,77$ , die nominale Effizienz auf  $E(3) = 0,59$ . Das Diagramm macht zwei Dinge sichtbar: den nahezu idealen Gewinn beim Übergang von einem auf zwei Worker und die leichte Verschlechterung durch einen dritten Worker, obwohl dessen Hinzunahme in einer idealen parallelen Maschine einen weiteren Gewinn bringen müsste.




Abbildung 10: Gesamtzeit aller sechs Anfragen in Minuten für 1, 2 und 3 Worker mit dem jeweiligen Speedup über den Balken.

Tabelle 6 fasst die Kennzahlen zusammen. Der Durchsatz steigt von 779 auf 1482 Kandidaten pro Sekunde und fällt mit drei Workern auf 1376 zurück. Entsprechend sinken die Kosten pro Kandidat von 1,28 auf 0,68 Millisekunden und steigen mit drei Workern wieder auf 0,73 Millisekunden. Aus  $S(2) = 1,90$  ergibt sich nach der Formel aus Definition 10 ein nicht parallelisierter Anteil von etwa  $f \approx 5\%$ . Dieser Wert fasst alle seriellen Anteile zusammen, darunter das Laden der bis zu 326.000 Zeilen aus PostgreSQL, die Serialisierung der Matrizen für die Prozesskommunikation und den Aufbau der Trefferliste. Eine getrennte Zuordnung auf die einzelnen Phasen erlauben die vorliegenden Daten nicht, weil die Phasenzeiten im aktuellen Code nicht protokolliert werden.

Tabelle 6: Kennzahlen der Suche in Abhängigkeit von der Worker-Anzahl (jeweils 6 Anfragen,  $C_\Sigma = 1.249.054$  Kandidaten).

| $p$ | $T(p)$ [s] | Mittel [s] | Median [s] | Max. [s] | $S(p)$ | $E(p)$ | $\Theta(p)$ [1/s] | $\kappa(p)$ [ms] |
|-----|------------|------------|------------|----------|--------|--------|-------------------|------------------|
| 1   | 1604       | 267,4      | 324,9      | 403,2    | 1,00   | 1,00   | 779               | 1,28             |
| 2   | 843        | 140,5      | 169,4      | 212,0    | 1,90   | 0,95   | 1482              | 0,68             |
| 3   | 908        | 151,3      | 183,9      | 224,6    | 1,77   | 0,59   | 1376              | 0,73             |

### 7.5.3 Verteilung der Antwortzeiten

Abbildung 11 stellt die Antwortzeiten der einzelnen Anfragen als Boxplots dar. Die Zeitachse ist logarithmisch, weil die Zeiten über mehr als eine Größenordnung streuen. Die Box umfasst das untere bis obere Quartil, die orange Linie markiert den Median, das grüne Dreieck den Mittelwert, und die Antennen reichen bis zur kleinsten bzw. größten Messung. Mit einem Worker liegen die Zeiten zwischen 70,0 und 403,2 Sekunden; das untere Quartil beträgt rund 164 Sekunden, das obere rund 359 Sekunden, der Median




Abbildung 11: Verteilung der Antwortzeit pro Anfrage als Boxplot mit logarithmischer Zeitachse und Mittelwert (Dreieck) für 1, 2 und 3 Worker.

324,9 Sekunden und der Mittelwert 267,4 Sekunden. Mit zwei Workern verschiebt sich die gesamte Verteilung nach unten: Die Zeiten reichen von 36,7 bis 212,0 Sekunden, die Quartile liegen bei rund 85 und 191 Sekunden, der Median bei 169,4 und der Mittelwert bei 140,5 Sekunden. Auf der logarithmischen Achse ist die Verschiebung für Minimum, Median und Maximum nahezu gleich groß, die Boxen haben also dieselbe Form. Das bedeutet, dass die Parallelisierung alle Anfragen unabhängig von ihrer Größe um etwa denselben Faktor beschleunigt und nicht nur besonders große oder kleine. Mit drei Workern liegt die Verteilung geringfügig oberhalb derjenigen mit zwei Workern (Median 183,9 Sekunden, Maximum 224,6 Sekunden), aber deutlich unterhalb der Verteilung mit einem Worker.

Der Median liegt bei jeder Worker-Anzahl über dem Mittelwert. Die Verteilung ist also linksschief: Wenige kurze Anfragen, nämlich die beiden Queries mit 19 Knoten und vergleichsweise kleiner Kandidatenmenge, ziehen den Mittelwert herunter, während vier Anfragen mit großem Suchraum die Laufzeit bestimmen. Wegen der geringen Stichprobe von nur sechs Werten sind die Quartile grobe Orientierungswerte; das 95-%-Quantil, das das Skript ebenfalls ausgibt, ist bei sechs Werten identisch mit dem Maximum und wird deshalb hier nicht gesondert aufgeführt.

#### 7.5.4 Skalierung mit der Größe des Suchraums

Abbildung 12 trägt für jede Anfrage und jede Worker-Anzahl die Antwortzeit gegen die Zahl der Kandidaten nach der SQL-Vorauswahl auf. Die Punkte jeder Worker-Anzahl liegen sehr nahe an einer Geraden, was Hypothese H3 stützt. Der Pearson-Korrelationskoeffizient zwischen  $C$  und Antwortzeit beträgt 0,996 für einen Worker, 0,996 für zwei und 0,990 für drei Worker. Die lineare Regression liefert für einen Worker eine Steigung von etwa 1,3 Millisekunden je Kandidat, für zwei Worker etwa 0,70 und für drei Worker etwa 0,75 Millisekunden. Die Gerade für einen Worker verläuft also etwa doppelt so steil wie die Geraden für zwei und drei Worker, die ihrerseits fast aufeinander liegen, wobei die Punkte für drei Worker durchgehend leicht höher liegen. Die Parallelisierung




Abbildung 12: Streudiagramm der Antwortzeit gegen die Kandidatenzahl nach der SQL-Vorauswahl für 1, 2 und 3 Worker.

ändert damit den Anstieg, nicht die Form des Zusammenhangs: Eine Verdopplung der Kandidatenzahl verdoppelt weiterhin die Suchzeit, nur mit etwa der halben Steigung.

Zugleich zeigt das Diagramm, dass der Zusammenhang nicht exakt proportional ist. Die Kosten pro Kandidat (Tabelle 5, aus den Zeiten  $t_1$  berechnet) betragen für die Anfragen mit 15 oder 16 Knoten zwischen 1,24 und 1,35 Millisekunden, für die beiden Anfragen mit 19 Knoten dagegen nur 1,13 und 1,19 Millisekunden. Die Regressionsgerade besitzt entsprechend einen negativen Achsenabschnitt. Aus der Kubikschranke  $O(n^3)$  ließe sich für Queries mit mehr Knoten ein höherer, nicht ein niedrigerer Aufwand pro Vergleich erwarten. Die Schranke ist aber eine Worst-Case-Abschätzung für den Vergleich; die Messung zeigt, dass der tatsächliche Aufwand auf diesen Daten auch von anderen Faktoren abhängt, etwa davon, wie früh ein Vergleich entschieden werden kann. Eine belastbare Erklärung erlaubt die vorliegende Messreihe nicht, weil dafür Zeiten einzelner Vergleiche in Abhängigkeit von  $n_Q$  und  $n_k$  erhoben werden müssten.

### 7.5.5 Dieselben Anfragen im direkten Vergleich

Abbildung 13 ordnet die Anfragen auf der horizontalen Achse nach ihrer Laufzeit mit einem Worker und zeichnet für jede Worker-Anzahl einen Linienzug durch die zugehörigen Zeiten. Weil dieselben Anfragen in allen drei Messreihen verwendet wurden, zeigt jeder vertikale Schnitt dieselbe Anfrage unter drei Bedingungen. Die Linie für einen Worker liegt an jeder Stelle oberhalb der beiden anderen, die Linien für zwei und drei Worker verlaufen nahezu parallel zueinander, wobei die Linie für drei Worker für alle sechs Anfragen über der für zwei Worker liegt. Auf der logarithmischen Achse entspricht ein konstanter Faktor einem konstanten vertikalen Abstand; dass die Abstände zwischen den Linien über alle Positionen annähernd gleich bleiben, bestätigt, dass die Beschleunigung von der Größe der Anfrage weitgehend unabhängig ist. Der Speedup  $S(2)$  liegt für die einzelnen Anfragen zwischen 1,87 und 1,93 (Tabelle 5), der Speedup  $S(3)$  zwischen 1,70 und 1,84. Diese




Abbildung 13: Antwortzeit jeder einzelnen Anfrage bei 1, 2 und 3 Workern, sortiert nach der Zeit mit einem Worker, logarithmische Zeitachse.

enge Streuung ist ein Hinweis, dass der Gesamtwert  $S(2) = 1,90$  keine Folge einzelner Ausreißer ist. Besonders deutlich ist der Sprung von der zweiten zur dritten Position: Die Anfrage 3 ist mit 221.027 Kandidaten wesentlich aufwendiger als die Anfrage 6 mit 100.911 Kandidaten, und der Abstand zwischen den Linien bleibt trotzdem derselbe.

## 7.6 Diskussion

**Hypothese H1.** Der Übergang von einem auf zwei Worker liefert einen Speedup von 1,90 bei einer Effizienz von 95 %, und alle sechs Anfragen liegen zwischen 1,87 und 1,93. Die Hypothese ist damit auf dem untersuchten Rechner bestätigt: Der parallelisierbare Vergleichsanteil dominiert die Laufzeit, und der serielle Anteil von etwa 5 % (Laden der Kandidaten, Prozesskommunikation, Aufbau der Trefferliste) begrenzt den Gewinn nur geringfügig. Die Messung stützt das in Abschnitt 7.1 angegebene Modell  $T_{\text{parallel}} = O(\frac{C}{p}n^3) + O(n^3)$ , wobei der additive Term nur den langsamsten Einzelvergleich erfasst. Die Messung zeigt, dass zusätzlich ein mit  $C$  wachsender serieller Anteil existiert, der in diesem Modell nicht abgebildet ist. Er fällt bei  $p = 2$  kaum ins Gewicht, würde bei größerem  $p$  aber nach dem Gesetz von Amdahl zunehmend den erreichbaren Speedup bestimmen.

**Hypothese H2.** Mit drei Workern auf einem Rechner mit zwei logischen Prozessoren steigt die Gesamtzeit um rund 7,7 % gegenüber zwei Workern, und der Speedup fällt von 1,90 auf 1,77. Auch diese Hypothese wird bestätigt. Die Vergleiche sind rein rechengebunden; ein dritter Prozess erzeugt keine zusätzliche Rechenkapazität, sondern konkurriert mit den anderen Prozessen um dieselben zwei Prozessoren und verursacht zusätzliche Kontextwechsel. Hinzu kommt, dass auch der Hauptprozess, der die Ergebnisse einsammelt, und der PostgreSQL-Server auf demselben Rechner Rechenzeit benötigen. Welchen

Anteil diese Effekte jeweils haben, lässt sich aus den Daten nicht trennen. Die Beobachtung lässt sich aber unmittelbar in eine Konfigurationsempfehlung übersetzen: Die Zahl der Worker sollte die Zahl der verfügbaren logischen Prozessoren nicht überschreiten. Die mitgelieferte `.env`-Datei setzt `SUBGRAPH_MAX_WORKERS=14`; dieser Wert ist nur auf einem Rechner mit mindestens vierzehn logischen Prozessoren sinnvoll und sollte für andere Systeme angepasst werden.

**Hypothese H3.** Die Antwortzeit hängt mit einem Korrelationskoeffizienten von mindestens 0,99 linear von der Kandidatenzahl ab. Das stimmt mit dem Term  $O(C \cdot n^3)$  aus Satz 2 bei beschränktem  $n$  überein. Die Abweichungen in den Kosten pro Kandidat zeigen allerdings, dass die Konstante nicht allein durch die Knotenzahl bestimmt wird (siehe oben).

**Bedeutung für das Korollar zur Datenbankgröße.** Das Korollar zu Satz 2 behauptet eine von  $N$  unabhängige Suchzeit, sofern die Kandidatenzahl durch ein Limit  $K$  beschränkt ist. Das Experiment läuft bewusst ohne Limit und zeigt die Kehrseite: Bei  $N \approx 10^6$  bleiben je nach Query bis zu 32,6 % der Datenbank als Kandidaten übrig, und die Suchzeit steigt dann proportional zu  $C$  auf bis zu 403 Sekunden mit einem und 212 Sekunden mit zwei Workern. Ohne Limit wächst  $C$  bei fester Selektivität des Pre-Filters linear mit  $N$ , und damit auch die Suchzeit. Die Parallelisierung verkleinert den Anstieg um etwa den Faktor  $p$ , hebt die Abhängigkeit von  $N$  aber nicht auf. Wer harte Latenzgrenzen einhalten will, braucht deshalb weiterhin einen schärferen Pre-Filter (etwa den in Abschnitt 8 diskutierten mehrdimensionalen Index) oder ein Kandidatenlimit mit den dort beschriebenen Einbußen bei der Vollständigkeit; die Parallelisierung ergänzt diese Maßnahmen, ersetzt sie aber nicht.

## 7.7 Grenzen der Untersuchung

Die Ergebnisse sind als erste empirische Einordnung zu lesen und aus folgenden Gründen nicht ohne Weiteres verallgemeinerbar.

- **Kleine Stichprobe.** Mit sechs Anfragen und einer Messung je Anfrage und Worker-Anzahl lassen sich keine Standardabweichungen über Wiederholungen und keine Signifikanztests angeben. Dass die Speedups der einzelnen Anfragen eng beieinander liegen, spricht für stabile Verhältnisse, ersetzt aber keine Wiederholungsmessungen. Die ursprünglich vorgesehenen 50 Anfragen sollten auf einem Rechner mit mehr Prozessoren nachgeholt werden.
- **Zwei logische Prozessoren.** Aussagen für  $p > 2$  beschränken sich auf die Überbelegung; das Skalierungsverhalten bei vier, acht oder vierzehn echten Prozessoren, insbesondere der Einfluss des seriellen Anteils, wird nicht gemessen. Die Abschätzung  $f \approx 5\%$  beruht auf einem einzigen Messpunkt.
- **Gemeinsam genutzter Rechner.** Datenbank, Hauptprozess und Worker teilen sich dieselben Prozessoren. Auf einem System mit separatem Datenbankserver würde sich der serielle Anteil anders verhalten. Die Absolutwerte sind außerdem nicht mit dem Serverprotokoll aus Abschnitt 4.6 vergleichbar, das auf einem anderen System entstand.

- **Keine Phasenzerlegung.** Der Code protokolliert die Zeiten für Laden, Vergleichen und Trefferaufbau nicht, weshalb das Diagramm „Zeit je Phase“ des Skripts leer bleibt und dieser Abschnitt auf seine Wiedergabe verzichtet. Der serielle Anteil kann daher nur indirekt aus dem Speedup abgeschätzt werden.
- **Eine synthetische Graphenfamilie.** Alle Netzwerke stammen aus dem Erdős-Rényi-Modell mit  $p = 0,3$ ; für reale biologische Netzwerke mit anderer Dichte und Struktur können Kandidatenzahlen, Trefferquoten und Kosten pro Vergleich abweichen.
- **Treffer von Query und Kandidat.** Da die Queries aus der Datenbank stammen, enthält jede Kandidatenmenge das Query-Netzwerk selbst. Das ist für die Laufzeitmessung unerheblich, spricht aber gegen eine Interpretation der Trefferzahlen als allgemeine Trefferquote.

## 7.8 Zwischenfazit

Die parallele Ausführung der Kandidatenvergleiche über einen Prozess-Pool beschleunigt die Suche in Gen-DB auf dem untersuchten Rechner mit zwei logischen Prozessoren um den Faktor 1,90 (Effizienz 95 %); der Gewinn ist für alle sechs Anfragen nahezu gleich. Ein dritter Worker verschlechtert die Zeit um rund 8 %, da keine zusätzliche Rechenkapazität zur Verfügung steht. Die Suchzeit wächst unabhängig von der Worker-Zahl linear mit der Kandidatenzahl und erreicht ohne Kandidatenlimit bei großen Suchräumen mehrere Minuten, sodass die Parallelisierung die Antwortzeit um einen konstanten Faktor senkt, aber die Notwendigkeit eines selektiveren Pre-Filters oder eines Kandidatenlimits nicht beseitigt. Für die Praxis folgt daraus die Empfehlung, die Worker-Anzahl an die Zahl der logischen Prozessoren anzupassen. Die offene Frage, wie weit sich der Gewinn auf Rechnern mit deutlich mehr Prozessoren fortsetzt, soll eine Wiederholung der Messreihe mit der vollen Anfragezahl klären.

## 8 Schluss

Die vorliegende Arbeit hat Gen-DB, ein System zur Subgraph-Suche in Datenbanken biologischer Netzwerke, von der Architektur über die formale Analyse der Such-Pipeline bis zu mehreren empirischen Untersuchungen betrachtet. Dieser abschließende Abschnitt gliedert sich in fünf Teile: Zunächst fasst Abschnitt 8.1 die Ergebnisse aller vorangegangenen Abschnitte zusammen und gleicht sie mit den in der Einleitung formulierten Beiträgen ab. Abschnitt 8.2 benennt die Grenzen der Arbeit, sodass die Ergebnisse richtig eingeordnet werden können. Abschnitt 8.3 entwickelt darauf aufbauend ausführlich mögliche Erweiterungen und offene Forschungsfragen, geordnet nach Themenfeldern. Abschnitt 8.4 schlägt schließlich eine Reihenfolge für die Umsetzung vor, und Abschnitt 8.5 schließt die Arbeit mit einer Gesamteinschätzung.

### 8.1 Zusammenfassung

#### 8.1.1 Ausgangspunkt und Zielsetzung

Biologische Datenbanken enthalten Millionen von Netzwerken: metabolische Pfade, Protein-Interaktionsnetzwerke und Gen-Regulationsnetzwerke. Eine zentrale Aufgabe bei

ihrer Analyse ist die Subgraph-Suche, bei der zu einem Query-Netzwerk alle gespeicherten Netzwerke gefunden werden sollen, die das Query als Teilstruktur enthalten. Diese Arbeit hat untersucht, wie sich der Subgraph Algorithmus [1], der zwei Adjazenzmatrizen über Spaltensignaturen und zyklische längste gemeinsame Teilsequenzen in  $O(n^3)$  vergleicht, in eine relationale Datenbank einbetten lässt, ob die entstehende Such-Pipeline formal korrekt und analysierbar ist und wie sie sich bei einer Datenbank mit einer Million Einträgen tatsächlich verhält.

### 8.1.2 Systemarchitektur und Datenmodell

Gen-DB besteht aus drei Schichten: einem Web-Frontend in HTML, CSS und JavaScript, einem FastAPI-Backend in Python und einer PostgreSQL-Datenbank. Das Datenmodell speichert Metadaten (Name, Netzwerktyp, Organismus, Knoten- und Kantenanzahl) in der Tabelle `biological_networks` und die strukturellen Repräsentationen (Knotenlabels, Adjazenzmatrix, Signatur-Array und Signatur-Hash) in der 1:1-verknüpften Tabelle `network_matrices`. Entscheidend für die Suche ist, dass Knoten- und Kantenanzahl als eigene, indizierte Spalten vorliegen, sodass sie ohne Zugriff auf die Matrizen ausgewertet werden können. Die UML-Paket- und Klassendiagramme in Abschnitt 3.3 dokumentieren, dass die Zerlegung in Präsentation, Logik und Persistenz sauber getrennt ist. Dadurch lässt sich die Such-Pipeline als eigenständiger Baustein formalisieren. Für die Ausführung der Vergleiche besitzt das Backend einen Prozess-Pool, der die Kandidaten blockweise auf mehrere Worker-Prozesse verteilt (Abschnitt 7).

### 8.1.3 Formale Ergebnisse zur Such-Pipeline

Die Pipeline besteht aus zwei Stufen. Die erste ist eine datenbankseitige Vorauswahl, die nur Netzwerke mit mindestens so vielen Knoten und Kanten wie das Query zulässt. Die zweite ist der strukturelle Vergleich der verbliebenen Kandidaten mit dem Subgraph Algorithmus. Gezeigt wurde Folgendes:

- Die Vorauswahl ist korrekt: Aus  $A_Q \preceq A_k$  folgt  $n_Q \leq n_k$  und  $m_Q \leq m_k$  (Lemma 2). Damit scheidet der Pre-Filter keinen Treffer der Richtung  $A_Q \preceq A_k$  fälschlich aus (Korollar 1).
- Die Gesamtlaufzeit beträgt  $T_{\text{Suche}}(N, C, n) = O(\log N + C) + O(C \cdot n^3)$  (Satz 2). Bei beschränkter Knotenzahl und beschränkter Kandidatenzahl  $K$  ist die Suchzeit unabhängig von der Datenbankgröße  $N$ .
- Ohne Kandidatenlimit ( $K = \infty$ ) findet die Pipeline alle Treffer der Richtung  $A_Q \preceq A_k$  (Satz 3). Mit Limit gilt dies nur noch eingeschränkt, weil ein sortiertes LIMIT Treffer mit großer Knotenzahl systematisch abschneiden kann (Lemma zur Verzerrung durch LIMIT).
- Die symmetrische Richtung  $A_k \preceq A_Q$  wird von der Vorauswahl nicht abgedeckt und braucht eine eigene Filterbedingung.

### 8.1.4 Empirische Evaluation der Datenbank

Als Testdatenbank dienten 1.000.000 synthetische Netzwerke (zuzüglich zweier Beispielnetzwerke) mit gleichverteilter Knotenzahl  $n_k \in \{3, \dots, 20\}$ , Kantenwahrscheinlichkeit

$p = 0,3$  und gleichverteilten Netzwerktypen und Organismen. Im Mittel hatten sie 11,5 Knoten und 44,3 Kanten. Die Verteilungen entsprachen den Erwartungen aus dem Generierungsmodell, einschließlich der Abweichung der mittleren Kantenzahl vom naiven Erwartungswert, die sich durch die Jensen-Ungleichung erklärt. Die Auswertung zeigte, dass allein die Knotenzahlbedingung den Suchraum je nach Querygröße um bis zum Faktor 18 verkleinert, und die Kantenbedingung die Reduktion weiter verstärkt. Die Modellkurven zur Skalierung bestätigten die Aussage des Korollars zu Satz 2: Mit Kandidatenlimit bleibt die Suchzeit näherungsweise konstant, ohne Limit wächst sie linear in  $N$ .

### 8.1.5 Experimenteller Vergleich mit VF2

In einer direkten Messung gegen VF2 [10] auf Erdős–Rényi-Graphen  $G(n, 0,3)$  war der Subgraph Algorithmus bei festem  $n_A = 5$  und  $n_B \in [5, 13]$  um den Faktor 1,9 bis 4,7 schneller. Der Vorsprung schmolz bei  $n_B = 14$  bis 16 auf etwa 1,1 ab, und bei  $n_B = 17$  und 18 war VF2 mit Speedups von 0,83 und 0,82 etwas schneller. Bei gemeinsam wachsendem  $n = n_A = n_B$  stieg die Laufzeit des Subgraph Algorithmus von 0,055 ms ( $n = 4$ ) auf 1,309 ms ( $n = 12$ ), also um den Faktor 23,8 und damit in der Größenordnung der kubischen Referenz  $3^3 = 27$ , während VF2 im selben Bereich nur um den Faktor 2,8 wuchs. Die Ursachenanalyse hat dies auf vier Punkte zurückgeführt: eine Referenzimplementierung ohne vorzeitigen Abbruch, das frühe Terminieren von VF2 auf zufälligen dichten Graphen, den Interpreter-Overhead der Python-Implementierung und den grundsätzlichen Unterschied zwischen Worst-Case-Schranke und Durchschnittsverhalten. Die Literaturübersicht hat gezeigt, dass der Subgraph Algorithmus unter den betrachteten Verfahren das einzige mit unbedingt polynomieller Worst-Case-Schranke ist, dafür aber eine strukturell schwächere Relation entscheidet als die volle Subgraph-Isomorphie. Daraus wurde eine Hybridstrategie abgeleitet, bei der je nach Graphgröße zwischen beiden Verfahren gewählt und der Subgraph Algorithmus als Fallback mit garantierter Schranke behalten wird.

### 8.1.6 Parallelisierung der Kandidatenvergleiche

Die Messreihe mit sechs aus der Datenbank gezogenen Queries (mindestens 15 Knoten, 62.064 bis 325.964 Kandidaten, kein Kandidatenlimit) hat die parallele Ausführung quantifiziert. Mit zwei Workern sank die Gesamtzeit aller Anfragen von 1604 auf 843 Sekunden, das entspricht einem Speedup von 1,90 und einer Effizienz von 95 %, für jede einzelne Anfrage zwischen 1,87 und 1,93. Aus dem Speedup ergibt sich ein serieller Anteil von etwa 5 %. Ein dritter Worker auf dem Rechner mit zwei logischen Prozessoren verschlechterte die Gesamtzeit um rund 8 % ( $S(3) = 1,77$ ), weil keine zusätzliche Rechenkapazität entsteht. Die Antwortzeit wuchs mit einem Korrelationskoeffizienten von mindestens 0,99 linear mit der Kandidatenzahl. Eine einzelne Suche dauerte ohne Parallelisierung bis zu 403 Sekunden und mit zwei Workern bis zu 212 Sekunden.

### 8.1.7 Zentrale Erkenntnisse

Aus der Gesamtschau lassen sich sieben Erkenntnisse festhalten:

1. **Die Architektur trägt die Analyse.** Die klare Trennung zwischen relationaler Kandidatenreduktion und algorithmischem Strukturvergleich erlaubt es, beide Stufen getrennt zu beweisen, zu messen und zu optimieren.

2. **Der Pre-Filter ist notwendig, aber allein nicht ausreichend.** Er verkleinert den Suchraum erheblich, doch bei kleinen oder spärlichen Queries bleiben Hunderttausende Kandidaten übrig. Bei den sechs Messanfragen lagen zwischen 6,2 % und 32,6 % der Datenbank im Suchraum.
3. **Die Suchzeit wird von den Vergleichen dominiert.** Sie wächst linear mit der Kandidatenzahl, so wie es der Term  $O(C \cdot n^3)$  aus Satz 2 erwarten lässt.
4. **Garantie und Geschwindigkeit sind zwei verschiedene Eigenschaften.** Der Subgraph Algorithmus bietet eine bewiesene polynomielle Schranke und vorhersagbare Laufzeiten. Auf kleinen dichten Zufallsgraphen kann ein Verfahren mit exponentieller Worst-Case-Schranke wie VF2 im Durchschnitt gleich schnell oder schneller sein.
5. **Parallelisierung ist ein verlässlicher, aber begrenzter Hebel.** Sie senkt die Antwortzeit auf dem untersuchten System um einen konstanten Faktor nahe der Prozessorzahl, ändert aber nichts an der linearen Abhängigkeit von  $C$ . Sie ersetzt deshalb weder einen schärferen Pre-Filter noch ein Kandidatenlimit.
6. **Die Worker-Zahl muss zur Hardware passen.** Mehr Worker als logische Prozessoren verschlechtern die Laufzeit. Die mitgelieferte Voreinstellung von vierzehn Workern ist deshalb nur auf entsprechend ausgestatteten Rechnern sinnvoll.
7. **Vollständigkeit und Geschwindigkeit stehen im Spannungsfeld.** Ein Kandidatenlimit macht die Suchzeit unabhängig von  $N$ , kostet aber die Vollständigkeitsgarantie. Auch die Suchrichtung ist nur für  $A_Q \preceq A_k$  abgesichert.

### 8.1.8 Abgleich mit den Beiträgen der Arbeit

In der Einleitung wurden acht Beiträge angekündigt. Sie sind wie folgt erfüllt: Die formale Beschreibung der Architektur und die Einbettung des Algorithmus in die relationale Datenbank sind in Abschnitt 3 geleistet. Korrektheit und Komplexität der Pipeline sind in Abschnitt 4 bewiesen, jedoch mit der ausdrücklichen Einschränkung auf die Richtung  $A_Q \preceq A_k$  und den Fall ohne Kandidatenlimit. Die empirische Evaluation an einer Million Netzwerke und die zugehörigen Diagramme finden sich in Abschnitt 5. Der Vergleich mit VF2 samt Ursachenanalyse folgt in Abschnitt 6, die Untersuchung der Parallelisierung in Abschnitt 7. Zusammenfassung, Würdigung der Grenzen und Ausblick bilden dieses Kapitel. Ein Unterschied in der Belastbarkeit ist zu beachten: Die Skalierungskurven in Abschnitt 5 beruhen auf dem analytischen Modell, während die Abschnitte 6 und 7 gemessene Werte zeigen. Dieser Punkt wird in Abschnitt 8.2 noch einmal aufgegriffen.

## 8.2 Kritische Würdigung und Grenzen

Die Ergebnisse dieser Arbeit sind belastbar, soweit es um die formalen Aussagen geht. Für die empirischen Aussagen gelten die folgenden Einschränkungen, die bei der Interpretation berücksichtigt werden müssen.

1. **Die entschiedene Relation ist nicht die Subgraph-Isomorphie.** Die zyklische, auf den Zeilenkomponenten der Signaturen beruhende Relation  $\preceq$  ist strukturell schwächer als die klassische Subgraph-Isomorphie. Treffer von Gen-DB sind daher Treffer im Sinne von  $\preceq$  und nicht ohne Weiteres im Sinne der Isomorphie.

Die Laufzeitvergleiche mit VF2 vergleichen deshalb Größenordnungen und nicht die Mächtigkeit der Relationen.

2. **Nur eine Suchrichtung ist abgesichert.** Die Vollständigkeitsaussage gilt für  $A_Q \preceq A_k$ . Für die umgekehrte Richtung fehlt eine bewiesene Vorauswahl.
3. **Kandidatenlimit und Implementierungsstand.** Die Analyse in Abschnitt 4 modelliert ein optionales Kandidatenlimit  $K$ , und das dort gezeigte SQL-Statement enthält eine LIMIT-Klausel. Die für die Messungen in Abschnitt 7 verwendete Programmfassung führt dagegen den Vergleich über alle Kandidaten aus. Beides ist mit den Sätzen vereinbar, die Textstellen sollten bei einer Überarbeitung jedoch auf einen einheitlichen Stand gebracht werden.
4. **Teilweise modellbasierte Auswertung.** Die Skalierungskurven in Abschnitt 5 beruhen auf dem analytischen Laufzeitmodell und nicht auf Messungen. Gemessen sind der Vergleich mit VF2 (Abschnitt 6) und die Parallelisierung (Abschnitt 7).
5. **Synthetische Daten.** Alle Netzwerke stammen aus dem Erdős–Rényi-Modell mit  $p = 0,3$ . Reale biologische Netzwerke sind häufig skalenfrei, haben hohe Clusterkoeffizienten und Hub-Knoten. Kandidatenzahlen, Trefferquoten und Kosten pro Vergleich können dort deutlich abweichen.
6. **Geringe Stichprobengröße.** Der Vergleich mit VF2 beruht auf 8 bzw. 5 Wiederholungen je Datenpunkt, die Parallelisierungsmessung auf 6 Anfragen mit je einer Messung. Konfidenzintervalle und Signifikanztests fehlen.
7. **Begrenzte Hardware.** Die Parallelisierung wurde auf einem Rechner mit zwei logischen Prozessoren gemessen, auf dem auch die Datenbank lief. Aussagen zur Skalierung auf viele Prozessoren oder auf getrennte Datenbankserver sind daher Extrapolationen.
8. **Ungenutzte Knotenlabels.** Die Relation  $\preceq$  ignoriert Knotenlabels. Zwei strukturell gleiche, biologisch aber verschiedene Netzwerke gelten als äquivalent, was für die praktische Anwendung eine wesentliche Einschränkung ist.
9. **Referenzimplementierung ohne Optimierung.** Die Laufzeitwerte des Subgraph Algorithmus stammen aus einer in reinem Python geschriebenen Implementierung ohne vorzeitigen Abbruch. Sie sind daher eher eine obere Abschätzung des praktisch Erreichbaren.

### 8.3 Ausblick

Die Erweiterungsmöglichkeiten lassen sich in sechs Themenfelder ordnen: die Absicherung von Korrektheit und Suchsemantik, die Verschärfung der Vorauswahl und Indexierung, die Beschleunigung der Vergleiche, die Skalierung auf Systemebene, die Weiterentwicklung der Evaluation und die Anwendungsebene. Die folgenden Unterabschnitte behandeln jedes Feld einzeln. Wo eine Idee bereits durch die Ergebnisse dieser Arbeit gestützt oder relativiert wird, ist darauf verwiesen.

## Themenfeld A: Korrektheit und Suchsemantik

### 8.3.1 Vollständige Suche in beide Richtungen

Die Pipeline findet bisher nur Netzwerke, die das Query enthalten. Für die umgekehrte Richtung, bei der ein gespeichertes Netzwerk Teil des Querys ist, lässt sich dieselbe Argumentation wie in Lemma 2 anwenden: Aus  $A_k \preceq A_Q$  folgt  $n_k \leq n_Q$  und  $m_k \leq m_Q$ . Die zugehörige Kandidatenmenge ist

$$\mathcal{C}'(Q, \mathcal{D}) = \{(id_k, L_k, A_k) \in \mathcal{D} : n_k \leq n_Q \wedge m_k \leq m_Q\},$$

und eine vollständige Suche in beide Richtungen verarbeitet die Vereinigung  $\mathcal{C}(Q, \mathcal{D}) \cup \mathcal{C}'(Q, \mathcal{D})$ . Die beiden Mengen überschneiden sich genau in den Netzwerken mit  $n_k = n_Q$  und  $m_k = m_Q$ . Für die Praxis ist wichtig, dass  $\mathcal{C}'$  bei großen Queries sehr groß wird: Für  $n_Q = 20$  erfüllt fast jedes Netzwerk die Knotenbedingung  $n_k \leq 20$ . Eine Suche in Gegenrichtung ist deshalb nur mit einer Parallelisierung und mit einer Ergebnisbegrenzung sinnvoll und sollte in API und Oberfläche als eigener Suchmodus gekennzeichnet werden. Ob die Gegenrichtung für biologische Anwendungen überhaupt gebraucht wird (die Frage lautet dann: „Welche gespeicherten Motive stecken in meinem großen Netzwerk?“), ist eine fachliche Frage, die mit Anwendern geklärt werden sollte.

### 8.3.2 Differenzielle Tests der Vorauswahl und Eigenschaftstests

Die Korrektheit des Pre-Filters wurde bewiesen, aber nicht automatisiert geprüft. Ein wirksamer Test vergleicht auf kleinen Datenbanken (etwa tausend zufällige Netzwerke) die Ergebnisse der Pipeline mit einer vollständigen Suche ohne Vorauswahl, bei der jedes Netzwerk mit dem Subgraph Algorithmus verglichen wird. Beide Ergebnismengen müssen für die Richtung  $A_Q \preceq A_k$  identisch sein. Ergänzend können Eigenschaften, die aus der Definition der Relation folgen, als Eigenschaftstests (*property-based tests*) formuliert werden, etwa dass jedes Netzwerk Subgraph von sich selbst ist und dass der Vergleich nicht von der zyklischen Anordnung der Zeilenkomponenten abhängt. Solche Tests würden auch jede spätere Optimierung des Vergleichs (Abschnitt 8.3.8) absichern.

### 8.3.3 Erweiterung auf gewichtete und beschriftete Subgraph-Isomorphie

Die aktuelle Subgraph-Relation  $\preceq$  berücksichtigt ausschließlich die *Struktur* (Adjazenzmatrix), nicht jedoch die *Knotenlabels*  $L$  (z. B. **Glucose**, p53). Zwei strukturell identische, aber biologisch unterschiedliche Netzwerke (z. B. Glykolyse vs. ein Zufallsgraph gleicher Adjazenzmatrix) würden aktuell als äquivalent erkannt. Eine biologisch sinnvolle Erweiterung wäre eine *gefärbte* Subgraph-Relation

$$(L_Q, A_Q) \preceq_\ell (L_k, A_k) \iff A_Q \preceq A_k \wedge \exists \text{Knotenabbildung } \phi : L_Q(i) = L_k(\phi(i)) \ \forall i,$$

deren Prüfung zusätzlich eine Label-Kompatibilitätsprüfung in  $O(n)$  pro Rotation erfordert (Gesamtkomplexität bleibt  $O(n^3)$ , da  $O(n) \subseteq O(n^2)$ ). Für kontinuierliche Kantengewichte  $w : E \rightarrow \mathbb{R}_{\geq 0}$  (z. B. Reaktionsraten) wäre die binäre Signatur  $\sigma_j = \sum_i A_{ij}2^i + j2^n$  durch eine gewichtete Variante  $\sigma_j^w = \sum_i w_{ij}2^i + j2^n$  zu ersetzen, wobei die Injektivität aus Lemma 1 nur noch für endliche Wertebereiche  $w_{ij} \in \{0, \dots, W\}$  mit Basis  $W + 1$  statt 2 erhalten bliebe.

## Themenfeld B: Vorauswahl und Indexierung

### 8.3.4 Indexierung über Signatur-Hashes

Aktuell wird der Signatur-Hash  $h(A)$  zwar berechnet und gespeichert (Spalte `signature_hash`, indiziert über `idx_matrices_hash`), jedoch nicht für die Subgraph-Suche genutzt — er eignet sich nur für *exakte* Übereinstimmungen (inklusive Rotation, falls die Hashfunktion rotationsinvariant gestaltet wird). Eine Erweiterung bestünde darin, einen *rotationsinvarianten* Hash

$$h^*(A) = \min_{r \in \{0, \dots, n-1\}} \text{SHA256}(\text{str}(\text{rot}_r(\rho(A))))$$

zu definieren und zu indizieren. Damit ließen sich **exact**-Treffer (Korollar zu Satz 3 für  $A_Q \equiv A_k$  bis auf Rotation) in  $O(\log N)$  statt  $O(C \cdot n^3)$  finden, indem zunächst eine Hash-Gleichheitssuche durchgeführt wird und der teure Subgraph-Vergleich nur für **subgraph**-Treffer (echte Teilstruktur) verbleibt. Die Korrektheit dieser Optimierung folgt aus der Tatsache, dass  $h^*(A_Q) = h^*(A_k) \Rightarrow A_Q \preceq A_k \wedge A_k \preceq A_Q$  (Äquivalenz unter Rotation), was eine direkte Anwendung von Lemma 1 auf die Zeilenkomponenten ist.

### 8.3.5 Mehrdimensionale Indexstrukturen (R-Baum über $(n_k, m_k)$ )

Der aktuelle Pre-Filter nutzt zwei unabhängige B-Baum-Indizes (`node_count`, `edge_count`) und kombiniert sie via konjunktiver **WHERE**-Klausel, was PostgreSQL typischerweise durch Bitmap-Index-Scans mit anschließendem **AND** realisiert. Eine direktere Lösung wäre ein zweidimensionaler Index (z.B. GiST/R-Baum über das Tupel  $(n_k, m_k)$  als Punkt im  $\mathbb{R}^2$ ), der die Bedingung  $n_k \geq n_Q \wedge m_k \geq m_Q$  als achsenparallele Bereichsabfrage (“dominance query”) in  $O(\log N + C)$  statt der aktuellen Bitmap-Kombination beantwortet. Formal entspricht  $\mathcal{C}(Q, \mathcal{D})$  exakt der Menge der Punkte  $(n_k, m_k)$ , die den Punkt  $(n_Q, m_Q)$  im Sinne der Pareto-Dominanz dominieren — ein klassisches Problem der rechnerischen Geometrie, für das R-Bäume und  $k$ -d-Bäume  $O(\log N)$ -Anfragezeiten (amortisiert) erreichen.

### 8.3.6 Zusätzliche notwendige Bedingungen und Label-Indizes

Die Vorauswahl nutzt derzeit nur Knoten- und Kantenzahl. Jede weitere Größe, die sich billig aus der Datenbank lesen lässt und für  $A_Q \preceq A_k$  notwendig ist, würde den Suchraum weiter verkleinern. Solche Bedingungen müssen vor ihrer Verwendung aus der Definition von  $\preceq$  bewiesen werden, denn eine zu scharfe Bedingung würde echte Treffer ausschließen. Bei Einführung der beschrifteten Relation  $\preceq_\ell$  (Themenfeld A) ist dagegen eine sehr wirk-same Bedingung unmittelbar ableitbar: Das Multiset der Knotenlabels des Querys muss im Multiset der Labels des Kandidaten enthalten sein. PostgreSQL unterstützt für Array-Spalten wie `node_labels` GIN-Indizes mit dem Enthaltenseins-Operator `@>` [4], sodass diese Bedingung direkt im Index ausgewertet werden könnte. Biologische Queries enthalten meist seltene Labels (etwa p53), wodurch die Kandidatenmenge in diesem Fall um Größenordnungen kleiner würde als bei der reinen Zählung von Knoten und Kanten. Einfacher umzusetzen ist ein zusammengesetzter Index über `(node_count, edge_count)`, der die beiden bisher getrennten B-Baum-Indizes ersetzt, bevor der aufwendigere R-Baum-Ansatz nötig wird.

## Themenfeld C: Beschleunigung der Vergleiche

### 8.3.7 Weiterführende Parallelisierung

Die Parallelisierung der Kandidatenvergleiche ist in Gen-DB umgesetzt und in Abschnitt 7 vermessen. Die Messung zeigt zugleich, an welchen Stellen weitere Gewinne liegen. Das Modell  $T_{\text{parallel}}(C, n, p) = O(\frac{C}{p}n^3) + O(n^3)$  aus Abschnitt 7 übersieht, dass das Laden und Übertragen der Kandidaten ebenfalls mit  $C$  wächst. Ein realistischeres Modell lautet

$$T_{\text{parallel}}(C, n, p) = \underbrace{O(C \cdot n^2)}_{\text{Laden, Übertragung, Ergebnisaufbau (seriell)}} + \underbrace{O\left(\frac{C}{p} \cdot n^3\right)}_{\text{Vergleiche}} + O(n^3),$$

in dem der serielle Anteil nach dem Gesetz von Amdahl [15] den erreichbaren Speedup für große  $p$  auf etwa  $1/f$  begrenzt. Mit dem geschätzten Anteil  $f \approx 5\%$  wäre der Gewinn rechnerisch bei etwa dem zwanzigfachen Wert gedeckelt; da dieser Wert aus einem einzigen Messpunkt stammt, ist er nur ein Anhaltspunkt. Folgende Maßnahmen setzen am seriellen Anteil an:

- **Strömendes Laden.** Die Kandidaten werden derzeit mit einem einzigen Abruf vollständig in den Speicher gelesen. Ein serverseitiger Cursor würde sie in Blöcken liefern, sodass das Laden mit den Vergleichen überlappt und der Speicherbedarf bei  $C \approx 3 \cdot 10^5$  sinkt.
- **Query nur einmal pro Task übertragen.** Die Query-Matrix wird gegenwärtig für jeden Kandidaten mitgeführt; bei einem Block von 256 Vergleichen wird sie 256-mal serialisiert. Eine Übergabe pro Block oder pro Worker (etwa über einen Initialisierer des Prozess-Pools bei Beginn der Suche) würde den Kommunikationsaufwand senken.
- **Blockgröße anpassen.** Die Blockgröße von 256 Vergleichen ist ein Kompromiss zwischen Kommunikationsaufwand und Lastverteilung. Eine adaptive Wahl (kleinere Blöcke am Ende, um Leerlauf zu vermeiden) und eine Messreihe zur Blockgröße sind einfach umzusetzen.
- **Worker-Zahl automatisch an die Hardware anpassen.** Die Ergebnisse zeigen, dass mehr Worker als logische Prozessoren schaden. Die Konfiguration sollte deshalb standardmäßig an `os.cpu_count()` gebunden und eine Überschreitung mit einer Warnung quittiert werden. Dabei ist zu bedenken, dass der Hauptprozess und der Datenbankserver ebenfalls Rechenzeit beanspruchen.
- **Gleichzeitige Suchanfragen.** Der Prozess-Pool wird von allen Anfragen gemeinsam genutzt. Laufen mehrere lange Suchen gleichzeitig, konkurrieren sie um dieselben Worker. Eine Warteschlange mit Priorisierung kurzer Suchen oder ein Limit gleichzeitiger Suchen würde die Antwortzeit kleiner Anfragen schützen.

Für sehr große Kandidatenmengen oder viele Nutzer kommt zusätzlich die Verteilung über mehrere Rechner in Betracht, etwa mit Apache Spark und einer benutzerdefinierten Funktion für `compare_graphs`. Dabei muss der Kommunikationsaufwand für den Versand der Adjazenzmatrizen (je  $O(n^2)$  Bit) gegen den Rechengewinn  $O(n^3/p)$  abgewogen werden. Für  $n \leq 20$  stehen  $n^2 = 400$  Bit nur  $n^3 = 8000$  Operationen gegenüber, sodass sich

die Verteilung bei  $p \ll C$  lohnt. Das Gesetz von Gustafson [16] legt zudem nahe, bei mehr Prozessoren auch die Problemgröße zu steigern, also etwa größere Netzwerke oder Datenbanken zu bearbeiten, anstatt nur dieselbe Suche zu beschleunigen.

### 8.3.8 Optimierung der Implementierung des Vergleichs

Die Ursachenanalyse in Abschnitt 6.3 hat gezeigt, dass die Referenzimplementierung des Subgraph Algorithmus die Tabelle der längsten gemeinsamen Teilsequenz für jede Rotation vollständig aufbaut und in reinem Python arbeitet. Daraus ergeben sich drei Hebel, die die asymptotische Schranke  $O(n^3)$  nicht verändern, die gemessene Zeit aber erheblich senken können. Erstens kann die Suche über die Rotationen abgebrochen werden, sobald eine Rotation die Bedingung erfüllt; im günstigen Fall genügt dann eine einzige Tabelle. Zweitens lässt sich die Tabelle zeilenweise abbauen, wenn bereits feststeht, dass die geforderte Mindestlänge nicht mehr erreichbar ist. Drittens kann die innere Schleife mit `numpy` vektorisiert oder mit `numba` bzw. als C++-Erweiterung kompiliert werden. Da der Vergleich nach der Abschätzung in Abschnitt 7 etwa 95 % der Laufzeit ausmacht, wirkt jede Beschleunigung des Einzelvergleichs fast vollständig auf die Gesamtzeit durch; zusammen mit den Prozessen multiplizieren sich die Gewinne. Diese Maßnahmen müssen allerdings durch die differenziellen Tests aus Abschnitt 8.3.1 abgesichert werden, damit die Optimierung das Ergebnis nicht verändert.

### 8.3.9 GPU-Beschleunigung der Signatur- und LCS-Berechnung

Die Signaturberechnung (Schritt 1 des Subgraph Algorithmus) ist eine Matrix-Vektor-Operation der Form  $\sigma_j = \sum_i A_{ij}2^i + j2^n$ , die sich als gewichtete Spaltensummen mit Bitmasken-Gewichten  $2^i$  darstellen lässt — eine klassische BLAS-Level-2-Operation, die auf GPUs (CUDA, via CuPy oder PyTorch) hochparallel ausgeführt werden kann. Für  $C$  Kandidaten mit  $n \times n$ -Matrizen ergibt sich ein Tensor der Form  $(C, n, n)$ , dessen Signaturen in einem einzigen GPU-Kernel-Aufruf berechnet werden könnten, was Schritt 1 von  $O(C \cdot n^2)$  sequentiellen auf  $O(C \cdot n^2/P_{\text{GPU}})$  effektiv parallele Operationen reduziert ( $P_{\text{GPU}}$  = Anzahl CUDA-Kerne). Die LCS-Berechnung (Schritt 3) ist aufgrund der sequentiellen Abhängigkeiten der DP-Tabelle ( $dp[i][j]$  hängt von  $dp[i-1][j-1]$  ab) schwieriger zu parallelisieren, jedoch existieren Wellenfront-Parallelisierungen (Anti-Diagonalen der DP-Tabelle sind unabhängig berechenbar), die auf GPUs in  $O(n)$  Schritten mit  $O(n)$  Prozessoren statt  $O(n^2)$  sequentiellen Schritten realisierbar wären (Brent-Theorem).

### 8.3.10 Hybridstrategie: Adaptive Verfahrenswahl nach Kandidatengröße

Die in Abschnitt 6 beobachtete Umkehrung des Speedup-Verhältnisses bei  $n_B \approx 14$  (Tabelle 2, Abbildung 8) motiviert eine *adaptive Hybridstrategie*: Da sowohl  $n_A$  (Query-Größe  $n_Q$ ) als auch  $n_B$  (Kandidatengröße  $n_k$ ) zum Zeitpunkt des Vergleichs bekannt sind (sie sind Teil des Tupels  $(id_k, L_k, A_k, n_k, m_k) \in \mathcal{C}(Q, \mathcal{D})$ , vgl. Abschnitt 3), könnte die Vergleichsfunktion `compare_graphs` zur Laufzeit zwischen dem Subgraph Algorithmus und VF2 umschalten:

$$\text{Verfahren}(n_Q, n_k) = \begin{cases} \text{Subgraph Algorithmus} & \text{falls } \max(n_Q, n_k) < \theta \\ \text{VF2} & \text{falls } \max(n_Q, n_k) \geq \theta \end{cases}$$

mit einem aus den Messdaten von Abschnitt 6 kalibrierten Schwellwert  $\theta \approx 14$ .

**Satz 4** (Optimalität der Hybridstrategie auf Messbasis). Sei  $T_{\text{Sub}}(n)$  und  $T_{\text{VF2}}(n)$  die (für eine feste Graphenfamilie  $G(n, p)$  erwartete) Laufzeit beider Verfahren. Definiere  $T_{\text{Hybrid}}(n) = \min(T_{\text{Sub}}(n), T_{\text{VF2}}(n))$ . Dann gilt für jede Folge von Vergleichsanfragen  $(n^{(1)}, \dots, n^{(C)})$ :

$$\sum_{i=1}^C T_{\text{Hybrid}}(n^{(i)}) \leq \min \left( \sum_{i=1}^C T_{\text{Sub}}(n^{(i)}), \sum_{i=1}^C T_{\text{VF2}}(n^{(i)}) \right).$$

*Beweis.* Da  $T_{\text{Hybrid}}(n^{(i)}) \leq T_{\text{Sub}}(n^{(i)})$  und  $T_{\text{Hybrid}}(n^{(i)}) \leq T_{\text{VF2}}(n^{(i)})$  für jedes  $i$  nach Definition des Minimums gilt, folgt durch Summation über  $i = 1, \dots, C$  sofort  $\sum_i T_{\text{Hybrid}}(n^{(i)}) \leq \sum_i T_{\text{Sub}}(n^{(i)})$  und ebenso  $\leq \sum_i T_{\text{VF2}}(n^{(i)})$ , also auch  $\leq$  dem Minimum beider Summen.  $\square$

**Bemerkung 5.** Satz 4 ist im strengen Sinne trivial (eine punktweise Minimum-Strategie ist niemals schlechter als jede ihrer Komponenten), seine praktische Bedeutung liegt jedoch darin, dass er die Hybridstrategie als *strikt dominant* gegenüber jeder festen Verfahrenswahl ausweist — *vorausgesetzt*, der Umschalt-Overhead (Bestimmung von  $\max(n_Q, n_k)$  und Verzweigung) ist  $O(1)$ , was hier der Fall ist, da  $n_Q$  und  $n_k$  bereits in  $\mathcal{D}_t$  materialisiert vorliegen (Abschnitt 3). Die Schranke  $O(n^3)$  aus Satz 2 bleibt für die Hybridstrategie *nicht* formal erhalten, da  $T_{\text{VF2}}$  keine polynomielle Worst-Case-Schranke besitzt; für  $n \geq \theta$  würde die Pipeline daher weiterhin den Subgraph Algorithmus als *Fallback mit garantierter Schranke* benötigen, etwa mit einem Zeitbudget  $\tau$ : Falls VF2 nach  $\tau$  nicht terminiert hat, wird auf den Subgraph Algorithmus zurückgegriffen (*Race-Verfahren*). Dies verbindet die empirische Average-Case-Effizienz von VF2 (Abschnitt 6) mit der formalen Worst-Case-Garantie des Subgraph Algorithmus.

## Themenfeld D: Skalierung auf Systemebene

### 8.3.11 Asynchrone Suche mit Fortschrittsanzeige und Teilergebnissen

Eine Suche mit mehreren hunderttausend Kandidaten dauert Minuten (bis zu 403 Sekunden in Abschnitt 7) und blockiert den HTTP-Aufruf bis zum Ende. Für interaktive Nutzung eignet sich ein asynchrones Modell: Die API nimmt die Suche an, liefert sofort eine Kennung zurück und stellt den Fortschritt (verglichene Kandidaten von  $C$ ) sowie die bisher gefundenen Treffer über Abfrage, Server-Sent Events oder WebSockets bereit. Der Prozess-Pool liefert Ergebnisse bisher in der Reihenfolge der Kandidaten; mit `as_completed` oder blockweiser Ausgabe könnten Treffer sofort sichtbar werden. Da die Kandidaten nach Knotenzahl sortiert sind, ließe sich zusätzlich ein „Anytime“-Verhalten erreichen: Der Nutzer sieht früh erste Treffer und kann die Suche abbrechen. Das senkt die wahrgenommene Antwortzeit unabhängig von der tatsächlichen Gesamtzeit und ist ohne Änderung des Algorithmus möglich.

### 8.3.12 Approximative Suche und geschichtete Stichproben

Die Beschränkung  $K = 10.000$  (Abschnitt 4) gefährdet die Vollständigkeitsgarantie aus Satz 3, falls  $|\mathcal{C}(Q, \mathcal{D})| > K$ . Eine Abmilderung wäre eine *geschichtete Stichprobe*: Partitioniere  $\mathcal{C}(Q, \mathcal{D})$  in Schichten nach  $n_k$  (also  $\mathcal{C}_3, \dots, \mathcal{C}_{20}$ ) und ziehe aus jeder nichtleeren Schicht  $\mathcal{C}_i$  mindestens  $\lceil K/18 \rceil$  Kandidaten, bevor das verbleibende Budget proportional zur Schichtgröße verteilt wird. Dies garantiert, dass Treffer mit seltenen Knotenzahlen  $n_k$  (z. B.  $n_k = 20$ , am dünnsten besetzte Schicht) nicht systematisch unterrepräsentiert werden — ein Problem, das bei einfachem `LIMIT K` nach `ORDER BY node_count ASC` auftritt (kleine  $n_k$  werden bevorzugt, große  $n_k$  ggf. nie erreicht).

**Lemma 4** (Verzerrung durch LIMIT). Sei  $\mathcal{C}(Q, \mathcal{D})$  sortiert nach  $n_k$  aufsteigend und  $K < |\mathcal{C}(Q, \mathcal{D})|$ . Dann enthält das durch LIMIT  $K$  gelieferte Präfix  $\mathcal{C}_K$  keinen Kandidaten mit  $n_k > n^*$ , wobei  $n^*$  das kleinste  $n$  mit  $|\{k : n_k \leq n\}| \geq K$  ist.

*Beweis.* Da ORDER BY node\_count ASC eine totale Ordnung auf  $\mathcal{C}(Q, \mathcal{D})$  induziert und LIMIT  $K$  die ersten  $K$  Elemente dieser Ordnung zurückgibt, ist  $\mathcal{C}_K = \{k \in \mathcal{C}(Q, \mathcal{D}) : \text{rank}(n_k) \leq K\}$ . Per Definition von  $n^*$  als kleinstem Wert mit kumulativer Häufigkeit  $\geq K$  folgt  $n_k \leq n^*$  für alle  $k \in \mathcal{C}_K$ .  $\square$

Dieses Lemma motiviert formal die Notwendigkeit der oben skizzierten Schichtung für eine unverzerrte approximative Suche.

### 8.3.13 Caching häufiger Queries

Da biologische Analysen oft wiederholt nach denselben oder ähnlichen Motiven suchen (z. B. Standard-Pfadabschnitte der Glykolyse), bietet sich ein LRU-Cache auf Ebene des Signatur-Arrays  $\Sigma(A_Q)$  an: Wird  $\Sigma(A_Q)$  bereits für eine vorherige Anfrage berechnet, kann Schritt 1 des Subgraph Algorithmus übersprungen werden (Ersparnis  $O(n_Q^2)$  pro wiederholter Anfrage). Bei einer angenommenen Cache-Trefferquote  $\alpha \in [0, 1]$  reduziert sich die erwartete Laufzeit aus Satz 2 zu

$$\mathbb{E}[T_{\text{Suche}}] = (1 - \alpha) \cdot O(n_Q^2) + O(C \cdot n^3),$$

was insbesondere bei kleinem  $C$  (großes  $n_Q$ , vgl. Abbildung 4) relativ stärker zu Buche schlägt.

### 8.3.14 Inkrementelle Aktualisierung der Signatur-Indizes

Bei INSERT bzw. DELETE einzelner Netzwerke (wie in der Gen-DB-API über POST/DELETE /api/networks) werden Signaturen aktuell vollständig neu berechnet (Aufwand  $O(n^2)$  pro Operation, vernachlässigbar). Bei einer zukünftigen Erweiterung um *Batch-Updates* (Änderung mehrerer Kanten gleichzeitig) wäre jedoch eine inkrementelle Aktualisierung der Signaturen wünschenswert: Da  $\sigma_j = \sum_i A_{ij} 2^i + j 2^n$  linear in den Einträgen  $A_{ij}$  ist, lässt sich eine Änderung  $A_{ij} \rightarrow A'_{ij}$  als

$$\sigma'_j = \sigma_j + (A'_{ij} - A_{ij}) \cdot 2^i$$

in  $O(1)$  pro geänderter Kante nachführen, ohne die gesamte Spalte neu zu durchlaufen — eine direkte Konsequenz der Linearität der Signaturfunktion.

### 8.3.15 Betrieb, Reproduzierbarkeit und Beobachtbarkeit

Für den produktiven Betrieb sind mehrere organisatorische Erweiterungen sinnvoll. Die Dockerdateien des Projekts erlauben bereits einen reproduzierbaren Aufbau; sie sollten um einen automatisierten Testlauf und eine Messung der Suchzeit in einer Continuous-Integration-Pipeline ergänzt werden. Der Server sollte die Zeiten der einzelnen Phasen (Laden, Vergleichen, Ergebnisaufbau) und die Zahl der Kandidaten protokollieren oder als Metriken veröffentlichen. Das würde die in Abschnitt 7 fehlende Phasenerlegung liefern und den seriellen Anteil direkt messbar machen, anstatt ihn aus dem Speedup abzuschätzen. Eine Begrenzung von Anfragegröße, Laufzeit und Zahl gleichzeitiger Suchen schützt den Dienst vor Überlastung.

## Themenfeld E: Weiterentwicklung der Evaluation

### 8.3.16 Wiederholung und Erweiterung der Parallelisierungsmessung

Die Messreihe aus Abschnitt 7 ist als erste Einordnung gedacht und sollte in folgenden Punkten erweitert werden: (i) Wiederholung mit den ursprünglich vorgesehenen 50 Anfragen, damit Streuungsmaße und Konfidenzintervalle berechnet werden können; (ii) Durchführung auf Rechnern mit vier, acht, sechzehn und mehr echten Prozessoren, um die Kurve  $S(p)$  jenseits von  $p = 2$  zu bestimmen und den seriellen Anteil mit mehr als einem Messpunkt anzupassen; (iii) Trennung von Datenbankserver und Anwendung auf zwei Rechner, um zu klären, wie stark das Laden die Messung beeinflusst; (iv) Variation der Queries (Knotenzahlen oberhalb und unterhalb von 15, verschiedene Kantendichten), damit auch Suchen mit wenigen und mit sehr vielen Kandidaten abgedeckt sind; (v) Messung mit und ohne Kandidatenlimit; (vi) Vergleich verschiedener Blockgrößen. Mit diesen Daten ließen sich Amdahl- und Gustafson-Modell tatsächlich an Messwerte anpassen.

### 8.3.17 Benchmark-Suite und kontinuierliche Performanzmessung

Schließlich wäre die Entwicklung einer reproduzierbaren Benchmark-Suite sinnvoll, die die in Abschnitt 5 dargestellten Diagramme automatisch aus Live-Messungen (statt aus dem hier verwendeten analytischen Modell) generiert, etwa durch Instrumentierung der `search_subgraph`-Funktion mit `time.perf_counter()` und Protokollierung von  $(N, n_Q, m_Q, C, T_{\text{gemessen}})$ -Tupeln in einer separaten Metriktabelle. Eine solche Suite ermöglichte die empirische Validierung der in Satz 2 hergeleiteten asymptotischen Schranken und die Kalibrierung des Kandidatenlimits  $K$  in Abhängigkeit von einem Antwortzeit-Budget (z. B. 200 ms für interaktive Anwendungen). Die in Abschnitt 6 durchgeführten Experimente liefern hierfür einen konkreten Ausgangspunkt: `bench_compare.py` kann als Kern einer kontinuierlichen Integrationspipeline (CI) dienen, die bei jeder Änderung der Implementierung des Subgraph Algorithmus automatisch prüft, ob die gemessene Laufzeit weiterhin innerhalb der durch Satz 1 vorhergesagten Größenordnung liegt (Regressions-Schranke, z. B.  $T_{\text{Sub}}(n) \leq c \cdot n^3$  für eine aus historischen Messungen kalibrierte Konstante  $c$ ).

### 8.3.18 Erweiterung des Vergleichsbenchmarks

Die in Abschnitt 6 durchgeführten Experimente beschränken sich auf den Vergleich mit VF2 auf Erdős–Rényi-Zufallsgraphen  $G(n, 0,3)$  mit  $n \leq 18$ . Eine umfassendere Evaluation sollte folgende Erweiterungen umfassen:

- **Weitere Referenzalgorithmen:** Integration von Ullmann [11] (z. B. über `networkx.algorithms.isomorphism.GraphMatcher` mit ISMAGS oder externe Implementierungen von RI [13]), um die in Tabelle 3 rein literaturbasierte Einordnung durch eigene Messungen auf identischer Hardware zu ersetzen.
- **Reale biologische Netzwerke:** Statt  $G(n, p)$ -Zufallsgraphen sollten Benchmark-Datensätze wie die KEGG-Pathway-Datenbank (metabolische Netzwerke) oder der DIP/STRING-Datensatz (Protein-Interaktionsnetzwerke) verwendet werden, da reale biologische Netzwerke charakteristische Eigenschaften (Skalenfreiheit, hohe Clusterkoeffizienten, Hub-Knoten) aufweisen, die sowohl das Pruning-Verhalten von VF2/RI als auch die Verteilung der Zeilenkomponenten  $\rho(A)$  des Subgraph Algorithmus systematisch beeinflussen können.

- **Größere  $n$ :** Die hier durchgeführten Experimente decken  $n \leq 18$  ab (entsprechend dem Wertebereich  $\{3, \dots, 20\}$  aus der Gen-DB-Generierung, Abschnitt 5). Für  $n > 20$  (z. B. größere Stoffwechselnetzwerke mit 50–200 Knoten) wäre zu erwarten, dass die kubische Schranke des Subgraph Algorithmus zunehmend dominiert, während VF2/RI auf solchen Graphen — je nach Dichte und Symmetriegrad — entweder weiterhin sub-exponentiell bleiben (geringe Dichte, viele eindeutige Labels) oder in den exponentiellen Worst Case geraten (hohe Symmetrie, viele Automorphismen). Eine systematische Messreihe für  $n \in \{20, 30, 50, 100\}$  wäre daher ein wichtiger nächster Schritt.
- **Statistische Signifikanz:** Die hier verwendeten 8 bzw. 5 Wiederholungen pro Datenpunkt (Tabelle 2, Abbildung 9) genügen für eine erste Tendenzaussage, jedoch nicht für eine belastbare statistische Aussage (z. B. Konfidenzintervalle,  $t$ -Test auf Mittelwertunterschiede). Eine erweiterte Messreihe mit  $\geq 100$  Wiederholungen pro Konfiguration und expliziter Angabe von Konfidenzintervallen (95 %) wäre für eine Publikation in einer Fachzeitschrift erforderlich.
- **Implementierungssprache:** Die hier verwendete Referenzimplementierung des Subgraph Algorithmus ist reines Python mit `numpy`, während `networkx` ebenfalls in Python implementiert ist (mit C-Erweiterungen für einige Kernoperationen). Ein fairer Vergleich auf Implementierungsebene (z. B. beide Verfahren in C++ oder beide in einer JIT-kompilierten Umgebung wie `numba`) würde den Einfluss des Implementierungs-Overheads von der algorithmischen Komplexität trennen und die in Satz 1 bewiesene asymptotische Aussage von konstanten Faktoren isolieren.

### 8.3.19 Formale Charakterisierung des Übergangsbereichs $\theta$

Die empirisch beobachtete Umkehrung des Geschwindigkeitsvorteils bei  $n_B \approx 14$  (Abschnitt 6) wirft die Frage auf, ob sich der Schwellwert  $\theta$  aus Abschnitt 8.3.10 formal als Funktion der Graphdichte  $p$  charakterisieren lässt. Intuitiv gilt: Je größer  $p$ , desto eher findet VF2 *sehr früh* einen Match oder einen Konsistenzbruch (da fast jeder Knoten mit fast jedem anderen verbunden ist, sind die meisten Teilabbildungen  $\phi$  bereits nach wenigen Schritten konsistent oder inkonsistent), während die Kosten des Subgraph Algorithmus  $\Theta(n^3)$  *unabhängig* von  $p$  sind (Satz 1 macht keine Annahme über  $p$ ). Dies legt die folgende Vermutung nahe:

**Bemerkung 6** (Vermutung: Dichteabhängigkeit von  $\theta$ ). Für  $G(n, p)$  mit  $p \rightarrow 1$  (vollständige Graphen) konvergiert die erwartete VF2-Laufzeit gegen  $\Theta(n^2)$  (jede Teilabbildung ist sofort konsistent, das Pruning entscheidet nach  $O(n)$  Rekursionsschritten mit  $O(n)$  Aufwand pro Schritt für Konsistenzprüfung), während  $T_{\text{Sub}}(n) = \Theta(n^3)$  unverändert bleibt. Für  $p \rightarrow 0$  (sehr dünne Graphen) hingegen terminiert VF2 bei den meisten Knotenpaaren sofort durch Verletzung der Kantenbedingung, was ebenfalls zu  $\Theta(n^2)$  oder besser führt. Der Schwellwert  $\theta(p)$  wäre demnach für  $p$  nahe 0 und nahe 1 *kleiner* als für  $p \approx 0,3$ – $0,5$  (Bereich maximaler struktureller Unsicherheit, in dem VF2 die meisten Rekursionsschritte benötigt) — d. h.  $\theta(p)$  wäre als Funktion von  $p$  vermutlich *unimodal* mit Maximum bei mittlerer Dichte. Ein formaler Beweis dieser Vermutung würde eine probabilistische Analyse des VF2-Suchbaums auf  $G(n, p)$  erfordern, analog zu den in [10] angedeuteten, aber nicht vollständig ausgeführten Average-Case-Betrachtungen.

Eine systematische Messreihe über das zweidimensionale Gitter  $(n, p) \in \{4, \dots, 20\} \times \{0, 1, 0, 2, \dots, 0, 9\}$  — eine direkte Erweiterung des in Abschnitt 6 durchgeführten Experiments — würde die in Bemerkung 6 formulierte Vermutung empirisch prüfbar machen und gleichzeitig eine Tabelle  $\theta(p)$  liefern, mit der die Hybridstrategie aus Abschnitt 8.3.10 dichteadaptiv kalibriert werden könnte (d. h.  $\theta$  würde nicht als globale Konstante, sondern als Funktion der für den jeweiligen Kandidaten  $k$  aus  $m_k/(n_k(n_k - 1))$  geschätzten Dichte  $\hat{p}_k$  nachgeschlagen).

## Themenfeld F: Anwendungsebene

### 8.3.20 Visuelle Exploration und Graph-Layout

Das aktuelle Frontend zeigt Adjazenzmatrizen als Zahlentabellen und Listen. Eine Erweiterung um eine graphische Darstellung (Force-Directed-Layout, z. B. mittels D3.js oder Cytoscape.js) würde die Interpretierbarkeit von Suchergebnissen erheblich verbessern, insbesondere für die in Abschnitt 5 diskutierten **subgraph**-Treffer, bei denen die *Einbettung* des Query-Graphen im größeren Kontextgraphen visuell hervorgehoben werden könnte (z. B. durch Hervorhebung der  $n_Q$  Knoten, auf die  $\phi$  aus Abschnitt 8 (Label-Erweiterung) abbildet).

### 8.3.21 Validierung mit realen Anwendungsfällen

Der größte offene Punkt auf Anwendungsebene ist der Nachweis, dass die Suche für Biologinnen und Biologen nützliche Treffer liefert. Dazu sollten bekannte Motive (etwa Teilpfade der Glykolyse oder des p53-Netzwerks) gegen Datensätze aus öffentlichen Datenbanken gesucht und die Treffer von Fachleuten bewertet werden. Maßgeblich sind dabei die Präzision (wie viele Treffer sind fachlich sinnvoll) und die Vollständigkeit (werden bekannte Vorkommen gefunden). Die Ergebnisse ließen sich mit den Treffern etablierter Verfahren wie VF2 oder RI vergleichen und würden zeigen, an welchen Stellen die schwächere Relation  $\preceq$  zu Abweichungen führt. Erst eine solche Validierung beantwortet, ob die zyklische Relation für die Praxis hinreichend ist oder ob die gefärbte Variante und eine Verfeinerung durch VF2 als Nachprüfung der Treffer nötig sind.

## 8.4 Priorisierung der nächsten Entwicklungsschritte

Die beschriebenen Erweiterungen sollten in einer Reihenfolge umgesetzt werden, die zunächst die fachliche Korrektheit und Aussagekraft absichert, danach die Messbarkeit herstellt und erst anschließend die Laufzeit optimiert. Die Parallelisierung der Vergleiche, die zuvor als eine von mehreren möglichen Optimierungen aufgeführt war, ist inzwischen umgesetzt und gemessen; sie entfällt daher als eigener Entwicklungsschritt, nicht jedoch ihre Verfeinerung.

Die Reihenfolge trennt drei Ziele, die bei der Weiterentwicklung nicht miteinander verwechselt werden sollten: Vollständigkeit und semantische Korrektheit der Suche (Nummern 1 und 4), empirisch belastbare Aussagen über ihre Leistung (Nummern 2, 3 und 11) sowie Optimierungen für konkrete Antwortzeit- und Skalierungsanforderungen (Nummern 5 bis 10 und 12). Insbesondere bleibt bei einer Hybridstrategie mit VF2 die Worst-Case-Garantie nur dann erhalten, wenn ein Verfahren mit garantierter Schranke, etwa der Subgraph Algorithmus, als Fallback vorgesehen ist. Wo die Maßnahmen voneinander abhängen, gilt: Die Tests (Nr. 1) müssen vor jeder Optimierung des Vergleichs (Nr. 5

Tabelle 7: Vorgeschlagene Reihenfolge der Weiterentwicklung.

| Nr. | Maßnahme                                                                            | Nutzen                                                 | Aufwand           |
|-----|-------------------------------------------------------------------------------------|--------------------------------------------------------|-------------------|
| 1   | Differenzielle Tests der Vorauswahl, Eigenschaftstests (Abschnitt 8.3, Feld A)      | sichert Korrektheit und alle weiteren Optimierungen ab | gering            |
| 2   | Phasen- und Metrikprotokollierung (Feld D)                                          | macht seriellen Anteil messbar                         | gering            |
| 3   | Wiederholung der Parallelisierungsmessung (Feld E)                                  | belastbare Aussagen zu $S(p)$                          | gering bis mittel |
| 4   | Suche in beide Richtungen (Feld A)                                                  | vollständige Suchsemantik                              | mittel            |
| 5   | Optimierung des Einzelvergleichs: Abbruch, Vektorisierung (Feld C)                  | wirkt fast vollständig auf die Gesamtzeit              | mittel            |
| 6   | Verfeinerte Parallelisierung: strömendes Laden, Query pro Task, Blockgröße (Feld C) | kleinerer serieller Anteil                             | mittel            |
| 7   | Asynchrone Suche mit Teilergebnissen (Feld D)                                       | bessere Bedienbarkeit bei langen Suchen                | mittel            |
| 8   | Beschriftete Relation, Label-Indizes (Felder A und B)                               | fachlich sinnvollere und kleinere Trefferlisten        | mittel bis hoch   |
| 9   | Mehrdimensionaler Index, Hash-Index (Feld B)                                        | schärfere Vorauswahl                                   | mittel            |
| 10  | Hybridstrategie mit VF2 und Fallback (Feld C)                                       | Geschwindigkeit bei garantierter Schranke              | hoch              |
| 11  | Validierung mit realen Netzwerken (Feld F)                                          | Nachweis der Praxistauglichkeit                        | hoch              |
| 12  | GPU-Beschleunigung, verteilte Ausführung (Feld C)                                   | Skalierung für sehr große Datenbanken                  | hoch              |

und 10) stehen, und die Protokollierung (Nr. 2) vor der Verfeinerung der Parallelisierung (Nr. 6), weil sonst nicht erkennbar ist, ob eine Änderung den seriellen Anteil tatsächlich senkt.

## 8.5 Abschließende Bemerkung

Diese Arbeit beschreibt Gen-DB als Full-Stack-System zur Suche in biologischen Netzwerken und verbindet die Architektur mit der formalen Analyse der Such-Pipeline, mit einer Evaluation an einer Million synthetischer Netzwerke, einem Vergleich mit VF2 und einer Messung der Parallelisierung. Ihr zentraler Gedanke ist die Trennung zweier Aufgaben: Eine kostengünstige Vorauswahl in der Datenbank verkleinert den Suchraum, und der Subgraph Algorithmus entscheidet anschließend über jeden verbliebenen Kandidaten mit einer bewiesenen kubischen Zeitschranke. Diese Trennung hat sich in allen Teilen der Arbeit bewährt: Sie ermöglicht Korrektheits- und Komplexitätsbeweise, sie macht die Kandidatenzahl zur entscheidenden Stellgröße der Laufzeit, und sie erlaubt es, die teure Stufe unabhängig auf mehrere Prozessoren zu verteilen.

Die Ergebnisse zeigen aber auch, wo die Grenzen des gegenwärtigen Stands liegen. Eine vollständige Suche über eine Datenbank mit einer Million Einträgen dauert bei großen Suchräumen mehrere Minuten, und die Parallelisierung senkt diese Zeit um einen konstanten Faktor, nicht in der Größenordnung. Der Weg zu interaktiven Antwortzeit-

en führt deshalb über mehrere sich ergänzende Maßnahmen: eine schärfere Vorauswahl, einen schnelleren Einzelvergleich, eine Verfahrenswahl nach Graphgröße und eine Bedienung, die Teilergebnisse früh anzeigt. Zugleich bleibt zu klären, ob die zyklische Relation  $\preceq$  die fachlichen Anforderungen biologischer Anwender erfüllt, was eine Validierung an realen Netzwerken und die Einbeziehung der Knotenlabels verlangt. Gen-DB bietet dafür eine modulare Architektur, eine nachvollziehbare Kandidatenreduktion und ein reproduzierbares Experimentierwerkzeug. Die Arbeit benennt zugleich die Korrektheits- und Evaluationsschritte, die für den Übergang von der prototypischen Realisierung zu einem belastbar validierten Suchsystem erforderlich sind.

## Literatur

- [1] Stephan Epp. *Der Subgraph Algorithmus.*, 2026. Verfügbar unter: <https://github.com/naphets86/subgraph>.
- [2] Amir Abboud, Arturs Backurs, Virginia Vassilevska Williams. *Tight Hardness Results for LCS and Other Sequence Similarity Measures*. In: Proceedings of FOCS 2015.
- [3] Paul Erdős, Alfréd Rényi. *On Random Graphs I*. Publicationes Mathematicae (Debrecen), 6:290–297, 1959.
- [4] The PostgreSQL Global Development Group. *PostgreSQL 15 Documentation*. <https://www.postgresql.org/docs/15/>.
- [5] Sebastián Ramírez et al. *FastAPI Documentation*. <https://fastapi.tiangolo.com/>.
- [6] Thomas H. Cormen, Charles E. Leiserson, Ronald L. Rivest, Clifford Stein. *Introduction to Algorithms*, 4. Auflage. MIT Press, 2022.
- [7] Richard P. Brent. *The Parallel Evaluation of General Arithmetic Expressions*. Journal of the ACM, 21(2):201–206, 1974.
- [8] Antonin Guttman. *R-Trees: A Dynamic Index Structure for Spatial Searching*. In: Proceedings of ACM SIGMOD, 1984.
- [9] Robert A. Wagner, Michael J. Fischer. *The String-to-String Correction Problem*. Journal of the ACM, 21(1):168–173, 1974.
- [10] Luigi P. Cordella, Pasquale Foggia, Carlo Sansone, Mario Vento. *A (Sub)Graph Isomorphism Algorithm for Matching Large Graphs*. IEEE Transactions on Pattern Analysis and Machine Intelligence, 26(10):1367–1372, 2004.
- [11] Julian R. Ullmann. *An Algorithm for Subgraph Isomorphism*. Journal of the ACM, 23(1):31–42, 1976.
- [12] Aric A. Hagberg, Daniel A. Schult, Pieter J. Swart. *Exploring Network Structure, Dynamics, and Function using NetworkX*. In: Proceedings of the 7th Python in Science Conference (SciPy), 2008.
- [13] Vincenzo Bonnici, Rosalba Giugno, Alfredo Pulvirenti, Dennis Shasha, Alfredo Ferro. *A Subgraph Isomorphism Algorithm and Its Application to Biochemical Data*. BMC Bioinformatics, 14(Suppl 7):S13, 2013.

- [14] Huahai He, Ambuj K. Singh. *Graphs-at-a-time: Query Language and Access Methods for Graph Databases*. In: Proceedings of ACM SIGMOD, 2008.
- [15] Gene M. Amdahl. *Validity of the Single Processor Approach to Achieving Large Scale Computing Capabilities*. In: Proceedings of the AFIPS Spring Joint Computer Conference, 1967.
- [16] John L. Gustafson. *Reevaluating Amdahl's Law*. Communications of the ACM, 31(5):532–533, 1988.